

PROPOSAL TUGAS AKHIR

**IMPLEMENTASI VARIATIONAL AUTOENCODER DAN REGULARIZED
SINGULAR VALUE DECOMPOSITION PADA SISTEM REKOMENDASI FILM**



Ida Bagus Gede Basudewa Weda

NIM. 2208561077

PROGRAM STUDI INFORMATIKA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM


UNIVERSITAS UDAYANA

2024

LEMBAR PERSETUJUAN PROPOSAL TUGAS AKHIR

Judul : Implementasi Variational Autoencoder Dan Regularized Singular Value Decomposition Pada Sistem Rekomendasi Film
Nama : Ida Bagus Gede Basudewa Weda
NIM : 2208561077
Tanggal Seminar :

Disetujui Oleh :
Pendamping Proposal



Dr. Ir. Ngurah Agus Sanjaya ER, S.Kom., M.Kom.

NIP. 197803212005011001

Mengetahui,
Komisi Seminar dan Tugas Akhir
Program Studi Informatika
FMIPA UNUD
Ketua,

I Gusti Ngurah Anom Cahyadi Putra, ST., M.Cs.

NIP. 198403172019031005

KATA PENGANTAR

Proposal penelitian dengan judul Sistem Rekomendasi Pemilihan Laptop Menggunakan Metode Content-Based Filtering Dengan Algoritma VIKOR ini disusun dalam rangkaian kegiatan pelaksanaan Tugas Akhir di Program Studi Informatika FMIPA UNUD. Proposal ini disusun dengan harapan dapat menjadi pedoman dan arahan dalam melaksanakan penelitian di atas.

Sehubungan dengan telah terselesaikannya proposal ini, maka diucapkan terima kasih dan penghargaan kepada berbagai pihak yang telah membantu pengusul, antara lain:

1. Dr. Ir. Ngurah Agus Sanjaya ER, S.Kom., M.Kom. sebagai pembimbing proposal tugas akhir yang membantu menyempurnakan proposal ini.
2. Dr. Ir. I Ketut Gede Suhartana, S.Kom., M.Kom sebagai Koordinator Program Studi Informatika, FMIPA UNUD.
3. I Gusti Ngurah Anom Cahyadi Putra, ST., M.Cs. sebagai Komisi Seminar dan Tugas Akhir Program Studi Informatika
4. Bapak-bapak dan ibu-ibu dosen di program studi Informatika yang telah meluangkan waktu turut memberikan saran dan masukan dalam pelaksanaan penelitian;
5. Keluarga serta kawan-kawan di program studi Informatika yang telah memberikan dukungan moral dalam penyelesaian proposal ini.

Disadari pula bahwa sudah tentu proposal ini masih mengandung kelemahan dan kekurangan. Memperhatikan hal ini, maka masukan dan saran-saran penyempurnaan sangat diharapkan.

Bukit Jimbaran, April 2024

Penyusun

DAFTAR ISI

DAFTAR GAMBAR

DAFTAR TABEL

1. Latar Belakang

Di era informasi saat ini, kita dihadapkan dengan informasi yang hampir tak terhingga jumlahnya. Hal ini mengakibatkan terjadinya kesulitan dalam pengambilan keputusan, terutama ketika memilih produk, layanan, atau konten yang sesuai dengan preferensi kita. Sistem rekomendasi dapat digunakan untuk mengatasi masalah ini.

Sistem rekomendasi merupakan sistem yang berfungsi untuk memperkirakan dan memberikan informasi yang sekiranya menarik untuk seorang pengguna. Sistem rekomendasi menggunakan berbagai metode untuk memberikan saran produk berdasarkan preferensi dan kebutuhan pengguna seperti *content-based filtering*, *collaborative filtering*, dan metode *hybrid*. Metode *content-based filtering* bekerja dengan menganalisis atribut atau fitur dari item-item yang disukai oleh pengguna dan kemudian merekomendasikan item lain yang memiliki kemiripan atribut (Ayu et al., 2021). Metode *collaborative filtering* dapat dibagi menjadi dua kategori yaitu *memory-based* dan *model-based*. Kategori *memory-based* menggunakan tingkat similaritas untuk memberikan prediksi dengan mencari asosiasi antara pengguna dengan item (Rajput et al., 2024). Kategori *memory-based* dapat dikategorikan lagi menjadi *item-based* dan *user-based*. *Item-based* menganalisis bagaimana pengguna menilai suatu item dan mencari item dengan penilai yang mirip. *User-based* mencari pengguna yang mirip berdasarkan penilaian yang diberikan dan merekomendasikan item yang pengguna mirip sudah sukai ke pengguna target. *Model-based* menggunakan matriks pengguna-item sebagai data untuk membangun dan melatih sebuah model yang dapat memprediksi penilaian pengguna terhadap suatu item.

Salah satu tantangan utama dalam sistem rekomendasi adalah cold start problem. Cold start problem terjadi ketika sistem tidak memiliki cukup informasi tentang pengguna atau item baru, sehingga sulit untuk memberikan rekomendasi yang akurat. Tantangan lainnya adalah data sparsity, di mana data interaksi antara pengguna dan item mungkin tidak tersedia atau tidak lengkap.

Model *variational autoencoder* (VAE) dan *regularized singular value decomposition* (RSVD) merupakan dua teknik *model-based* yang dapat mengatasi tantangan sistem rekomendasi dan meningkatkan akurasi prediksi. VAE dapat membantu mengatasi cold start problem dan data sparsity dengan mempelajari representasi laten dari data, yang kemudian dapat digunakan untuk merekomendasikan item baru atau yang jarang diinteraksikan oleh pengguna. VAE juga dapat digunakan untuk menghasilkan rekomendasi yang lebih beragam dan mudah dipahami. RSVD dapat membantu meningkatkan akurasi prediksi sistem rekomendasi dengan cara mengurangi kebisingan, meningkatkan keterkaitan antara pengguna dan item, dan menangani data sparsity. Penggabungan VAE dan RSVD diharapkan dapat menghasilkan sistem rekomendasi yang lebih akurat, beragam, mudah dipahami, dan skalabel.

Penelitian ini bertujuan untuk mengembangkan sistem rekomendasi yang menggabungkan *variational encoder* dengan *regularized singular value decomposition* dan

mengevaluasi akurasi. Sistem rekomendasi akan dibuat dengan data film yang berisikan data historis interaksi antara pengguna dengan film.

2. Rumusan Masalah

Berdasarkan latar belakang yang telah dijabarkan, rumusan masalah pada penelitian ini adalah sebagai berikut :

1. Bagaimana performa sistem rekomendasi dengan *variational autoencoder* dan *regularized singular value decomposition*?
- 2.

3. Tujuan Penelitian

Berdasarkan latar belakang dan rumusan masalah yang telah dijabarkan, tujuan dari penelitian ini adalah sebagai berikut:

1. Mengetahui performa sistem rekomendasi yang menggunakan *variational autoencoder* dan *regularized singular value decomposition*
- 2.

4. Batasan Masalah

Terdapat beberapa batasan permasalahan dalam penelitian ini:

1. Data didapatkan secara sekunder melalui halaman web Kaggle/MovieLens.
2. Sistem hanya dapat memberikan rekomendasi item yang terdapat pada data.

5. Manfaat Penelitian

Manfaat dari hasil penelitian ini adalah:

1. Bagi Penonton

Penonton dapat dengan mudah mendapatkan rekomendasi yang sesuai dengan preferensi mereka.

2. Bagi Pembuat Film

Film yang dibuat dapat direkomendasikan kepada pengguna sesuai dengan preferensi mereka.

6. Tinjauan Pustaka

6.1 Tinjauan Teoritis

6.1.1 Sistem Rekomendasi

Sistem rekomendasi merupakan sistem yang berfungsi untuk memperkirakan dan memberikan informasi yang sekiranya menarik untuk seorang pengguna (Nugroho & Rahayu, 2020). Rekomendasi yang diberikan oleh sistem dapat digunakan oleh pengguna untuk mempertimbangkan apa yang harus mereka lakukan, seperti membeli barang atau menonton pertunjukan. Sistem ini banyak digunakan dalam berbagai industri, seperti e-commerce, media streaming, media sosial, dan lainnya.

6.1.2 Autoencoder

Autoencoder merupakan model *deep learning* yang merekonstruksi ulang data masukan pada lapisan luaran (Rajput et al., 2024). *Autoencoder* terdiri dari beberapa lapisan utama yaitu *encoder*, *hidden layer / bottleneck*, dan *decoder*. Lapisan *encoder* berfungsi untuk mereduksi dimensi dari data masukan. Lapisan *bottleneck* adalah komponen utama dari *autoencoder* dan menyimpan data masukan dalam bentuk yang sudah tereduksi. Lapisan *decoder* berfungsi untuk merekonstruksi data masukan menggunakan data yang sudah tereduksi.

6.1.2 Variational Autoencoder (VAE)

Variational Autoencoder (VAE) adalah jenis model *deep learning* yang digunakan dalam sistem rekomendasi untuk mengekstraksi representasi data yang lebih kompleks dan bersifat probabilistik. VAE memungkinkan sistem untuk secara efisien mempelajari distribusi laten (tersembunyi) dari data interaksi antara pengguna dan item (seperti produk atau konten) (Spina et al., 2024). Dengan memanfaatkan teknik ini, VAE mampu menghasilkan representasi yang lebih abstrak dan terstruktur dari preferensi pengguna terhadap berbagai item. Representasi ini kemudian dapat digunakan untuk memperbaiki ketepatan prediksi preferensi pengguna terhadap item yang belum diketahui atau belum dilihat, yang menjadi salah satu fokus utama dalam pengembangan sistem rekomendasi modern.


6.1.3 Regularized Singular Value Decomposition (RSVD)

6.2 Tinjauan Empiris

7. Metodologi Penelitian

7.1 Desain Sistem

Sistem rekomendasi yang akan dikembangkan menggunakan model *Variational Autoencoder* (VAE) dan metode *Regularized Singular Value Decomposition* (RSVD). VAE akan diberikan masukan berupa matriks interaksi antara pengguna dengan film dan menghasilkan representasi laten dari masukan tersebut. Representasi laten tersebut akan didekomposisi menggunakan RSVD untuk menghasilkan rekomendasi akhir.



Gambar 7.1 Diagram Alir Desain Sistem

7.2 Pengumpulan Data

Data yang digunakan merupakan data yang didapat secara sekunder dari situs web grouplens.org yang berjudul movielens 100k. Data movielens 100k berisikan beberapa file yaitu links.csv, movies.csv, tags.csv, dan ratings.csv. File yang akan digunakan pada penelitian ini adalah file ratings.csv yang berisikan 100.000 data rating yang diberikan oleh pengguna kepada film. Data memiliki beberapa kolom yaitu userId yang menandai id dari pengguna, movieId yang menandai ide dari film, rating yang menandai penilaian yang diberikan, dan timestamp yang menandai waktu penilaian diberikan. Contoh untuk data rating terdapat pada tabel 7.1.

Tabel 7.1 Contoh Data

userId	MovieId	rating	timestamp
1	1	4.0	964982703
1	3	4.0	964981247
1	6	4.0	964982224

1	47	5.0	964983815
1	50	5.0	964982931

7.3 Preprocessing Data

Preprocessing yang akan dilakukan terhadap data adalah menghilangkan atribut yang tidak digunakan dan mengubah data menjadi matriks *sparse*. Pada data rating, atribut *timestamp* tidak digunakan pada konteks penelitian ini maka atribut tersebut akan dihapus. Selanjutnya data dalam bentuk tabel akan diubah menjadi matriks *sparse* dimana setiap kolom akan merepresentasikan semua film dan setiap baris akan merepresentasikan pengguna. Sel pada matriks merepresentasikan rating yang diberikan oleh pengguna kepada film misalkan nilai pada baris i kolom j adalah nilai rating yang diberikan oleh pengguna ke- i untuk film ke- j . Contoh dari matriks *sparse* terdapat pada tabel 7.2

Tabel 7.2 Contoh Matriks *Sparse*

	1	2	3	4	5	...
1	4.0	0.0	4.0	0.0	0.0	...
2	0.0	0.0	0.0	0.0	0.0	...
3	0.0	0.0	0.0	0.0	0.0	...
4	0.0	0.0	0.0	0.0	0.0	...
...	...	...	...	...	...	...

7.4 Pengembangan Model *Variational Autoencoder*

Model *variational autoencoder* akan digunakan untuk mengubah matriks *sparse* rating menjadi representasi laten dan mereduksi dimensinya. Adapun lapisan-lapisan dari model yaitu :

- **Lapisan *Encoder***
Lapisan *encoder* berisikan beberapa lapisan *dense* dengan aktivasi nonlinear seperti ReLU. Lapisan ini akan menerima masukan berupa matriks *sparse* rating dan menghasilkan luaran berupa rata-rata (μ) dan *log-variance* ($\log(\sigma^2)$) dari distribusi Gaussian laten
- **Lapisan *Sampling***
Lapisan *sampling* adalah bagian yang memungkinkan *backpropagation* melalui proses *sampling* dengan menggunakan trik reparameterisasi. Sampel z akan diambil dari distribusi Gaussian menggunakan rumus
$$z = \mu + \sigma \cdot \epsilon$$
dimana ϵ merupakan sampel acak dari distribusi normal standar $N(0, I)$.
- **Lapisan *Decoder***
Lapisan *decoder* berisikan beberapa lapisan *dense* dengan aktivasi nonlinear seperti ReLU. Lapisan ini akan menerima masukan berupa sampel z dari distribusi laten dan menghasilkan luaran berupa rekonstruksi dari matriks *sparse* rating.

Fungsi *loss* akan digunakan untuk mengoptimalkan dua komponen yaitu *loss* rekonstruksi dan *KL-Divergence Loss* :

- *Loss* Rekonstruksi

Loss rekonstruksi digunakan untuk mengukur seberapa dekat rekonstruksi matriks yang dihasilkan dengan matriks masukan. Komponen ini digunakan untuk meminimalisir perbedaan antara data asli dengan data rekonstruksi. Fungsi yang digunakan adalah *mean squared error* (MSE).

- *KL-Divergence Loss*

KL-Divergence Loss digunakan untuk mengukur perbedaan antara distribusi laten $q(z|x)$ yang dipelajari oleh encoder dan distribusi prior $p(z)$.

$$KL(q(z|x)||p(z)) = -\frac{1}{2} \sum (1 + \log(\sigma^2) - \mu^2 - \sigma^2)$$

Jadi total fungsi loss yang digunakan adalah kombinasi antara *loss* rekonstruksi dan *KL-divergence loss*.

$$L_{VAE} = E_{q(z|x)}[\log p(x|z)] - KL(q(z|x)||p(z))$$

7.5 Regularized Singular Value Decomposition (RSVD)

Singular Value Decomposition atau SVD akan digunakan untuk mendekomposisi matriks representasi laten z yang didapatkan dari lapisan *encoder* pada VAE. Matriks z memiliki dimensi $m \times r$ dimana m adalah jumlah sampel data dan r adalah dimensi representasi laten yang dipilih dari VAE. Matriks z didekomposisi menjadi

$$z = U\Sigma V^T$$

dimana U merupakan matriks ortogonal $m \times r$ yang berisi vektor-vektor singular kiri, Σ adalah matriks diagonal $r \times r$ yang berisi nilai-nilai singular, dan V adalah matriks ortogonal $r \times r$ yang berisi vektor-vektor singular kanan.

7.6 Evaluasi Performa Rekomendasi

8 Jadwal Pelaksanaan Penelitian

Tabel 8.1 Rancangan Jadwal Pelaksanaan Penelitian

No.	Kegiatan	Bulan					
		1	2	3	4	5	6
1.	Studi Literatur						
2.	Analisis / Pengumpulan Data						
3.	Desain dan Perancangan Sistem						
4.	Implementasi Sistem						
5.	Pengujian Sistem						
6.	Penulisan Laporan Penelitian						

DAFTAR PUSTAKA