

PROPOSAL TUGAS AKHIR

**IMPLEMENTASI VARIATIONAL AUTOENCODER DAN REGULARIZED
SINGULAR VALUE DECOMPOSITION PADA SISTEM REKOMENDASI FILM**



Ida Bagus Gede Basudewa Weda

NIM. 2208561077

PROGRAM STUDI INFORMATIKA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS UDAYANA

JIMBARAN

2024

PROPOSAL TUGAS AKHIR

**IMPLEMENTASI VARIATIONAL AUTOENCODER DAN
REGULARIZED SINGULAR VALUE DECOMPOSITION PADA SISTEM
REKOMENDASI FILM**



Ida Bagus Gede Basudewa Weda

NIM. 2208561077

**PROGRAM STUDI INFORMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS UDAYANA
JIMBARAN**

2024

LEMBAR PERSETUJUAN PROPOSAL TUGAS AKHIR

Judul : Implementasi Variational Autoencoder Dan Regularized
Singular Value Decomposition Pada Sistem Rekomendasi
Film
Nama : Ida Bagus Gede Basudewa Weda
NIM : 2208561077
Tanggal Seminar : 25 Juli 2024

Disetujui Oleh :
Pendamping Proposal

Dr. Ir. Ngurah Agus Sanjaya ER, S.Kom., M.Kom.

NIP. 197803212005011001

Mengetahui,
Komisi Seminar dan Tugas Akhir
Program Studi Informatika
FMIPA UNUD
Ketua,

I Gusti Ngurah Anom Cahyadi Putra, ST., M.Cs.

NIP. 198403172019031005

LEMBAR PENGESAHAN PROPOSAL TUGAS AKHIR

Judul : Implementasi Variational Autoencoder Dan Regularized Singular Value Decomposition Pada Sistem Rekomendasi Film

Nama : Ida Bagus Gede Basudewa Weda

NIM : 2208561077

Tanggal Seminar : 25 Juli 2024

Disetujui oleh:

Cokorda Rai Adi Pramatha, ST. MM. PhD Ketua Penguji
NIP. 197806212006041002

Gst. Ayu Vida Mastrika Giri, S. Kom., M. Cs. Penguji 1
NIP. 199006062022032009

Dr. Ir. Ngurah Agus Sanjaya ER, S. Kom., Penguji 2
M. Kom.
NIP. 197803212005011001

Mengetahui,
Komisi Seminar dan Tugas Akhir
Program Studi Informatika
FMIPA UNUD
Ketua,

I Gusti Ngurah Anom Cahyadi Putra, ST., M. Cs

NIP. 198403172019031005

KATA PENGANTAR

Proposal penelitian dengan judul Implementasi Variational Autoencoder Dan Regularized Singular Value Decomposition Pada Sistem Rekomendasi Film ini disusun dalam rangkaian kegiatan pelaksanaan Tugas Akhir di Program Studi Informatika FMIPA UNUD. Proposal ini disusun dengan harapan dapat menjadi pedoman dan arahan dalam melaksanakan penelitian di atas.

Sehubungan dengan telah terselesaikannya proposal ini, maka diucapkan terima kasih dan penghargaan kepada berbagai pihak yang telah membantu pengusul, antara lain:

1. Dr. Ir. Ngurah Agus Sanjaya ER, S.Kom., M.Kom. sebagai pembimbing proposal tugas akhir yang membantu menyempurnakan proposal ini.
2. Dr. Ir. I Ketut Gede Suhartana, S.Kom., M.Kom sebagai Koordinator Program Studi Informatika, FMIPA UNUD.
3. I Gusti Ngurah Anom Cahyadi Putra, ST., M.Cs. sebagai Komisi Seminar dan Tugas Akhir Program Studi Informatika
4. Bapak-bapak dan ibu-ibu dosen di program studi Informatika yang telah meluangkan waktu turut memberikan saran dan masukan dalam pelaksanaan penelitian;
5. Keluarga serta kawan-kawan di program studi Informatika yang telah memberikan dukungan moral dalam penyelesaian proposal ini.

Disadari pula bahwa sudah tentu proposal ini masih mengandung kelemahan dan kekurangan. Memperhatikan hal ini, maka masukan dan saran-saran penyempurnaan sangat diharapkan.

Bukit Jimbaran, 25 Juli 2024

Ida Bagus Gede Basudewa Weda

DAFTAR ISI

LEMBAR JUDUL	i
LEMBAR PERSETUJUAN PROPOSAL TUGAS AKHIR	ii
KATA PENGANTAR.....	iv
DAFTAR ISI	v
DAFTAR GAMBAR	vii
DAFTAR TABEL.....	viii
1. Latar Belakang.....	1
2. Rumusan Masalah.....	2
3. Tujuan Penelitian	3
4. Batasan Masalah	3
5. Manfaat Penelitian	3
6. Tinjauan Pustaka	4
6.1 Tinjauan Teoritis.....	4
6.1.1 Sistem Rekomendasi.....	4
6.1.2 Collaborative Filtering.....	4
6.1.3 Variational Autoencoder (VAE)	5
6.1.4 <i>Regularized Singular Value Decomposition</i> (RSVD).....	7
6.1.5 Mean Squarred Error & Root Mean Squarred Error.....	9
6.2 Tinjauan Empiris	9
6.2.1 An autoencoder-based deep learning model for solving the sparsity issues of Multi-Criteria Recommender System (Rajput et al., 2024).....	9
6.2.2 Sistem Rekomendasi Suku Cadang Berdasarkan Item Based Filtering (Wibisono et al., 2021).....	10
6.2.3 Implementation of Dimensionality Reduction with SVD to Improve Rating Prediction in Recommender System (Mu'afa & Baizal, 2022)	10
7. Metodologi Penelitian.....	11
7.1 Desain Sistem	11
7.2 Pengumpulan Data	11
7.3 Perancangan Model	12
7.3.1 Preprocessing Data	12
7.3.2 Pengembangan Model Variational Autoencoder.....	14

7.3.3 Dekomposisi RSVD.....	14
7.4 Perancangan Sistem.....	15
7.5 Implementasi Sistem	16
7.6 Evaluasi Sistem Rekomendasi.....	16
8. Jadwal Pelaksanaan Penelitian.....	18
DAFTAR PUSTAKA	19

DAFTAR GAMBAR

Gambar 6.1. Struktur Lapisan VAE (Cai et al., 2023)	7
Gambar 7.1 Diagram Alir Desain Sistem.....	11
Gambar 7.2 Diagram Alir Perancangan Model.....	12
Gambar 7.3 Diagram Alir Preprocessing Data.....	13
Gambar 7.4 Ilustrasi Proses Pemisahan Data.....	13
Gambar 7.5 Diagram Alir Pengembangan VAE.....	14
Gambar 7.6 Diagram Alir Pengujian Model	17

DAFTAR TABEL

Tabel 7.1 Contoh Data Rating	12
Tabel 7.2 Contoh Data Film	12
Tabel 7.3 Contoh Matriks <i>Sparse</i>	13
Tabel 8.1 Rancangan Jadwal Pelaksanaan Penelitian	18

1. Latar Belakang

Industri perfilman mengalami peningkatan yang signifikan pada jumlah film yang diproduksi setelah terjadinya penurunan produksi yang disebabkan oleh terjadinya pandemi COVID-19 pada tahun 2020. Pada tahun 2021 produksi film meningkat sebesar 40% dan pada tahun 2022 meningkat sebesar 15%. Keuntungan yang diraup dari *Global box office* juga meningkat pada tahun 2022 meningkat sebesar 21,8% dan pada tahun 2023 meningkat sebesar 29,4% (Hancock et al., 2024). Peningkatan kuantitas film yang diproduksi dan keuntungan yang didapatkan akan memperbanyak film yang tersedia. Banyaknya film yang tersedia akan memberikan pilihan yang banyak kepada penonton, tetapi juga memberikan tantangan yaitu menemukan film yang sesuai dengan preferensi mereka. Sistem rekomendasi dapat digunakan untuk mengatasi tantangan ini.

Sistem rekomendasi merupakan sistem yang berfungsi untuk memperkirakan dan memberikan informasi yang sekiranya menarik untuk seorang pengguna. Sistem rekomendasi menggunakan berbagai metode untuk memberikan saran produk berdasarkan preferensi dan kebutuhan pengguna seperti *content-based filtering*, *collaborative filtering*, dan metode *hybrid*. Metode *content-based filtering* bekerja dengan menganalisis atribut atau fitur dari item-item yang disukai oleh pengguna dan kemudian merekomendasikan item lain yang memiliki kemiripan atribut (Ayu et al., 2021). Metode *collaborative filtering* dapat dibagi menjadi dua kategori yaitu *memory-based* dan *model-based*. Kategori *memory-based* menggunakan tingkat similaritas untuk memberikan prediksi dengan mencari asosiasi antara pengguna dengan item (Rajput et al., 2024). Kategori *memory-based* dapat dikategorikan lagi menjadi *item-based* dan *user-based*. *Item-based* menganalisis bagaimana pengguna menilai suatu item dan mencari item dengan penilai yang mirip. *User-based* mencari pengguna yang mirip berdasarkan penilaian yang diberikan dan merekomendasikan item yang pengguna mirip sudah sukai ke pengguna target. *Model-based* menggunakan matriks pengguna-item sebagai data untuk membangun dan melatih sebuah model yang dapat memprediksi penilaian pengguna terhadap suatu item.

Salah satu tantangan utama dalam sistem rekomendasi adalah data sparsity. Data sparsity merujuk pada situasi di mana interaksi antara pengguna dan item sangat sedikit atau jarang. Dalam sistem rekomendasi berbasis matriks, ini berarti matriks pengguna-item memiliki banyak nilai kosong atau tidak diketahui. Hal ini menyulitkan model untuk menemukan pola yang cukup kuat untuk memberikan rekomendasi yang akurat. Misalnya, dalam layanan streaming dengan ribuan film, kebanyakan pengguna mungkin hanya menonton atau memberikan rating pada sebagian kecil dari film yang tersedia, menyebabkan matriks menjadi sangat jarang terisi.

Model *variational autoencoder* (VAE) dan *regularized singular value decomposition* (RSVD) merupakan dua teknik *model-based* yang dapat mengatasi tantangan sistem rekomendasi dan meningkatkan akurasi prediksi. VAE dapat membantu mengatasi data sparsity dengan mempelajari representasi laten dari data, yang kemudian dapat digunakan untuk merekomendasikan item baru atau yang jarang diinteraksikan oleh pengguna. VAE juga dapat digunakan untuk menghasilkan rekomendasi yang lebih beragam dan mudah dipahami. RSVD dapat membantu meningkatkan akurasi prediksi sistem rekomendasi dengan cara mengurangi kebisingan, meningkatkan keterkaitan antara pengguna dan item, dan menangani data sparsity. Penggabungan VAE dan RSVD diharapkan dapat menghasilkan sistem rekomendasi yang lebih akurat.

Penelitian terkait sistem rekomendasi telah banyak dilakukan untuk mengatasi masalah data sparsity dan meningkatkan akurasi prediksi. (Rajput et al., 2024) dalam penelitian mereka, menggunakan autoencoder dan faktorisasi matriks dengan singular value decomposition (SVD) untuk mengatasi masalah sparsity dalam sistem rekomendasi multi-kriteria. Mereka menunjukkan bahwa penggabungan autoencoder dengan SVD mampu mengurangi masalah sparsity dan meningkatkan akurasi prediksi, dengan hasil MAE sebesar 0.3350 dan RMSE sebesar 0.4897 setelah 100 epoch. Penelitian lain oleh (Wibisono et al., 2021) mengembangkan sistem rekomendasi suku cadang menggunakan item-based collaborative filtering dan SVD. Hasil penelitian mereka menunjukkan bahwa SVD mampu mereduksi dimensi matriks rating dan mengurangi noise dalam data yang sparse, dengan hasil MAE sebesar 1.2752 dan RMSE sebesar 1.4882. Selain itu, (Mu'afa & Baizal, 2022) menggunakan kombinasi K-Means dan SVD dalam sistem rekomendasi film, menunjukkan bahwa penggunaan SVD setelah K-Means clustering mampu meningkatkan akurasi prediksi rating, dengan hasil RMSE sebesar 0.835 dibandingkan dengan 0.896 untuk K-Means saja. Penelitian-penelitian ini menunjukkan bahwa penggunaan teknik faktorisasi matriks seperti SVD, terutama jika digabungkan dengan metode lain seperti autoencoder atau clustering, dapat secara efektif menangani masalah sparsity dan meningkatkan kinerja sistem rekomendasi.

Berdasarkan penelitian yang sudah pernah dilakukan, penelitian ini bertujuan untuk memperdalam dan meningkatkan performa dari sistem rekomendasi dengan mengembangkan sistem rekomendasi yang menggabungkan *variational encoder* dengan *regularized singular value decomposition* dan mengevaluasi performanya. Sistem rekomendasi akan dibuat dengan data film yang berisikan data interaksi antara pengguna dengan film.

2. Rumusan Masalah

Berdasarkan latar belakang yang telah dijabarkan, rumusan masalah pada penelitian ini adalah sebagai berikut :

- a. Bagaimana performa sistem rekomendasi dengan *variational autoencoder* dan *regularized singular value decomposition* dalam menghasilkan rekomendasi?
- b. Bagaimana pengembangan model sistem rekomendasi *variational autoencoder* dan *regularized singular value decomposition*?
- c. Bagaimana model yang optimal untuk sistem rekomendasi dengan *variational autoencoder* dan *regularized singular value decomposition*?
- d. Bagaimana kinerja implementasi sistem rekomendasi yang menggunakan *variational autoencoder* dan *regularized singular value decomposition*?

3. Tujuan Penelitian

Berdasarkan latar belakang dan rumusan masalah yang telah dijabarkan, tujuan dari penelitian ini adalah sebagai berikut:

- a. Mengetahui performa sistem rekomendasi yang menggunakan *variational autoencoder* dan *regularized singular value decomposition* dalam menghasilkan rekomendasi.
- b. Mengetahui bagaimana pengembangan model sistem rekomendasi *variational autoencoder* dan *regularized singular value decomposition*.
- c. Mengetahui model yang optimal untuk sistem rekomendasi dengan *variational autoencoder* dan *regularized singular value decomposition*.
- d. Mengetahui kinerja implementasi sistem rekomendasi yang menggunakan *variational autoencoder* dan *regularized singular value decomposition*.

4. Batasan Masalah

Terdapat beberapa batasan permasalahan dalam penelitian ini:

- a. Data didapatkan secara sekunder dari situs web grouplens.org yang berjudul “movielens 100k”.
- b. Pengguna tidak dapat menonton film secara langsung pada sistem.
- c. Sistem hanya dapat memberikan rekomendasi item yang terdapat pada data.

5. Manfaat Penelitian

Manfaat dari hasil penelitian ini adalah:

- a. Bagi Penonton
Penonton dapat dengan mudah mendapatkan rekomendasi yang sesuai dengan preferensi mereka.
- b. Bagi Pembuat Film

Film yang dibuat dapat direkomendasikan kepada pengguna sesuai dengan preferensi mereka.

6. Tinjauan Pustaka

6.1 Tinjauan Teoritis

6.1.1 Sistem Rekomendasi

Sistem rekomendasi merupakan sistem yang berfungsi untuk memperkirakan dan memberikan informasi yang sekiranya menarik untuk seorang pengguna (Nugroho & Rahayu, 2020). Sistem rekomendasi bekerja dengan menganalisis data pengguna, seperti riwayat pembelian, tontonan, dan interaksi mereka dengan platform digital. Berdasarkan data tersebut, sistem rekomendasi dapat memprediksi apa yang disukai dan dibutuhkan pengguna, dan kemudian memberikan rekomendasi yang dipersonalisasi. Rekomendasi yang diberikan oleh sistem dapat digunakan oleh pengguna untuk mempertimbangkan apa yang harus mereka lakukan, seperti membeli barang atau menonton pertunjukan. Sistem ini banyak digunakan dalam berbagai industri, seperti e-commerce, media streaming, media sosial, dan lainnya.

6.1.2 Collaborative Filtering

Collaborative filtering adalah teknik yang digunakan dalam sistem rekomendasi untuk memberikan saran item kepada pengguna berdasarkan preferensi pengguna lain yang serupa (Sutjiningtyas et al., 2022). Sederhananya, sistem ini mencari pengguna yang memiliki selera yang sama dengan pengguna yang ingin mendapatkan rekomendasi, dan kemudian merekomendasikan item yang disukai oleh pengguna-pengguna tersebut. Contohnya, di situs web e-commerce, collaborative filtering dapat digunakan untuk merekomendasikan produk kepada pengguna berdasarkan produk yang telah mereka beli atau lihat sebelumnya, serta produk yang dibeli oleh pengguna lain yang memiliki profil serupa.

Collaborative filtering dapat dibagi menjadi dua kategori yaitu *memory-based* dan *model-based*. Kategori *memory-based* menggunakan tingkat similaritas untuk memberikan prediksi dengan mencari asosiasi antara pengguna dengan item (Rajput et al., 2024). Kategori *memory-based* dapat dikategorikan lagi menjadi *item-based* dan *user-based*. *Item-based* menganalisis bagaimana pengguna menilai suatu item dan mencari item dengan penilai yang mirip. *User-based* mencari pengguna yang mirip berdasarkan penilaian yang diberikan dan merekomendasikan item yang pengguna mirip sudah sukai ke

pengguna target. *Model-based* menggunakan matriks pengguna-item sebagai data untuk membangun dan melatih sebuah model yang dapat memprediksi penilaian pengguna terhadap suatu item.

6.1.3 Variational Autoencoder (VAE)

Variational autoencoder (VAE) adalah model *generatif* yang mempelajari representasi laten dari data masukan sebagai variabel acak (Cai et al., 2023). VAE mempelajari data sebagai

$$p(x, z) = p(x|z)p(z) \quad (1)$$

Dimana :

x = data masukan

z = representasi laten

$p(x, z)$ = distribusi bersama x dan z

$p(x|z)$ = probabilitas x diberikan z

$p(z)$ = prior z

Prior dari z adalah $p(z)$ yang biasanya merupakan distribusi Gaussian ($N(0, I)$). Posterior $p(z|x)$ dapat berupa distribusi non-linear non-gaussian dengan demikian tidak dapat dihitung secara langsung karena kompleksitasnya (*intractable*). VAE akan memperkirakan posterior dengan

$$q(z|x) = N(z|\mu(x), \sigma(x)) \quad (2)$$

Dimana :

$q(z|x)$ = distribusi aproksimasi $p(z|x)$

$\mu(x)$ = rata-rata, ditentukan oleh x

$\sigma(x)$ = varians, ditentukan oleh x

z = prior z

VAE mendefinisikan fungsi *loss* sebagai probabilitas estimasi dari $\log p(x)$ yang diformulasikan dengan rumus

$$\log p(x) = KL(q(z|x)||p(z|x)) + l \quad (3)$$

dimana Kullback-Leibler (KL) merupakan divergensi antara dua distribusi yaitu posterior $q(z|x)$ dengan posterior $p(z|x)$. Divergensi antara dua distribusi $q(x)$ dan $p(x)$ akan menghitung tingkat kesamaanya dan diformulasikan dengan rumus

$$KL(q(x)||p(x)) = \sum_x q(x) \frac{q(x)}{p(x)} = E_{q(x)} \frac{q(x)}{p(x)} \quad (4)$$

Karena $p(z|x)$ *intractable* dan KL bernilai positif, maka memaksimalkan $\log p(x)$ dapat dilakukan dengan memaksimalkan l dengan rumus

$$l = E_{q(z|x)} \log p(x|z) - KL(q(z|x)||p(z)) \quad (5)$$

Bagian pertama pada rumus memaksimalkan probabilitas x saat diberikan representasi laten z , ini bisa dilihat sebagai *loss* rekonstruksi. Bagian kedua meminimalkan perbedaan antara prior dan posterior yang diperkirakan oleh VAE.

Sama seperti *autoencoder* pada umumnya, VAE memiliki beberapa lapisan yaitu lapisan *encoder*, lapisan *sampling*, dan lapisan *decoder*.

- *Lapisan Encoder*
Lapisan *encoder* berfungsi untuk mengubah data masukan menjadi representasi laten. Lapisan ini akan menghasilkan luaran berupa rata-rata (μ) dan log dari variasi ($\log(\sigma^2)$) dari distribusi Gaussian laten
- *Lapisan Sampling*
Lapisan *sampling* adalah bagian yang memungkinkan *backpropagation* melalui proses *sampling* dengan menggunakan trik reparameterisasi. Sampel z akan diambil dari distribusi Gaussian menggunakan rumus


$$z = \mu + \sigma \cdot \epsilon \quad (6)$$

Dimana :

- μ = rata-rata distribusi
- σ = varians distribusi
- ϵ = sampel acak dari distribusi normal standar $N(0, I)$.

- *Lapisan Decoder*
Lapisan *decoder* berfungsi untuk merekonstruksi data dari representasi laten. Lapisan ini akan menerima masukan berupa sampel z dari distribusi laten dan menghasilkan luaran berupa rekonstruksi dari data masukan.

Gambaran untuk struktur dari VAE terdapat pada gambar 6.1.



Gambar 6.1. Struktur Lapisan VAE (Cai et al., 2023)

6.1.4 Regularized Singular Value Decomposition (RSVD)

Singular Value Decomposition merupakan salah satu teknik faktorisasi matriks yang memecah sebuah matriks menjadi matriks-matriks yang lebih sederhana (Wibisono et al., 2021). Matriks A berukuran $m \times n$ yang didekomposisi dengan SVD dapat dinyatakan sebagai

$$A = U\Sigma V^T \quad (7)$$

dimana U adalah matriks ortogonal berukuran $m \times r$ yang berasal dari nilai *eigenvector* dari $M^T M$, Σ adalah matriks diagonal berukuran $r \times r$ yang memiliki nilai-nilai singular non-negatif disepanjang diagonal utamanya, dan V^T adalah matriks ortogonal berukuran $r \times n$ yang berasal dari nilai *eigenvector* dari MM^T .

Penambahan teknik regularisasi dapat mengubah *singular value decomposition* menjadi *regularized singular value decomposition* (RSVD). Teknik regularisasi ditambahkan untuk mencegah *overfitting* dan meningkatkan kemampuan generalisasi model. RSVD dimulai dengan adanya matriks yang ingin difaktorisasi misalnya matriks Z , dilanjutkan dengan membuat matriks U , V , dan Σ (matriks diagonal) dengan nilai acak. Salah satu teknik regularisasi yang dapat digunakan adalah regularisasi L2 atau *Ridge Regularization* yang memiliki fungsi *loss*

$$Loss = \sum_{i,j} (Z_{ij} - (U\Sigma V^T)_{ij})^2 + \lambda(\|U\|_F^2 + \|\Sigma\|_F^2 + \|V\|_F^2) \quad (8)$$

Dimana :

Z = matriks yang didekomposisi

U, V, Σ = matriks inisialisasi awal

λ = bobot penalti regularisasi

$\|x\|_F^2$ = norma Frobenius x

Bagian pertama menghitung *loss* rekonstruksi dan bagian kedua adalah penalti regularisasi L2. $\|U\|_F$ merupakan norma Frobenius dari matriks U . Norma Frobenius merupakan analog dari norma Euclidean untuk matriks. Jika matriks merupakan vektor panjang, maka norma

Frobenius adalah panjang vektor tersebut. Rumus untuk menghitung norma Frobenius dari sebuah matriks A dengan dimensi $m \times n$ adalah

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2} \quad (9)$$

Dimana :

a_{ij} = elemen baris ke- i , kolom ke- j , pada matriks A

Metode *Stochastic Gradient Descent* (SGD) akan digunakan untuk mengoptimasi fungsi *loss* dari RSVD. SGD adalah metode yang memperbarui parameter secara iteratif menggunakan informasi gradien dari subset data pada matriks Z (Wang et al., 2024). Pembaruan parameter pada SGD dilakukan dengan rumus

$$U \leftarrow U - \eta \frac{\partial \text{Loss}}{\partial U} \quad (10)$$

$$V \leftarrow V - \eta \frac{\partial \text{Loss}}{\partial V} \quad (11)$$

$$\Sigma \leftarrow \Sigma - \eta \frac{\partial \text{Loss}}{\partial \Sigma} \quad (12)$$

dimana η adalah *learning rate* dan turunan parsial dari fungsi *loss* terhadap U , V , Σ diformulasikan dengan rumus

$$\frac{\partial \text{Loss}}{\partial U_{uk}} = -2 \sum_{i=1}^n e_{ui} (\Sigma V^T)_{ki} + 2\lambda U_{uk} \quad (13)$$

$$\frac{\partial \text{Loss}}{\partial V_{ik}} = -2 \sum_{u=1}^m e_{ui} (\Sigma U^T)_{ku} + 2\lambda V_{ik} \quad (14)$$

$$\frac{\partial \text{Loss}}{\partial \Sigma_{kk}} = -2 \sum_{u=1}^m \sum_{i=1}^n e_{ui} U_{uk} V_{ik} + 2\lambda \Sigma_{kk} \quad (15)$$

Dimana :

e_{ui} = error rekonstruksi untuk baris ke- u dan kolom ke- i

$$e_{ij} = Z_{ij} - (U \Sigma V^T)_{ij} \quad (16)$$

$(\Sigma V^T)_{ki}$ = elemen ke- k , i dari hasil perkalian ΣV^T

$(\Sigma U^T)_{ku}$ = elemen ke- k , u dari hasil perkalian ΣU^T

V_{ik} = elemen ke i , k dari matriks V

U_{uk} = elemen ke u , k dari matriks U

λ = bobot regularisasi

Bagian pertama adalah gradien dari *loss* rekonstruksi dan bagian kedua adalah gradien penalti regularisasi. Iterasi ini terus dilakukan hingga mencapai konvergensi yaitu ketika perubahan nilai pada matriks menjadi sangat kecil atau fungsi *loss* tidak berkurang secara signifikan.

6.1.5 Mean Squarred Error & Root Mean Squarred Error

Mean Squarred Error (MSE) dan Root Mean Squarred Error (RMSE) merupakan dua metrik yang sering digunakan untuk mengukur kinerja sebuah model. Untuk sampel sebanyak n data asli yang disimbolkan dengan y dimana $(y_i, i = 1, 2, \dots, n)$ dan data prediksi model sebanyak n yang disimbolkan dengan $\hat{y}$ dimana $(\hat{y}_i, i = 1, 2, \dots, n)$ maka rumus MSE dan RMSE-nya adalah (Hodson, 2022)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (17)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (18)$$

Dimana :

y_i = data asli ke- i

$\hat{y}_i$ = data prediksi ke- i

n = jumlah data

MSE memberikan penilaian untuk besar kesalahan prediksi model dalam satuan kuadrat, sedangkan RMSE memberikan penilaian dalam satuan yang sama dengan variabel yang diprediksi. Nilai MSE dan RMSE yang rendah menunjukkan kinerja model yang bagus dalam memprediksi data, sebaliknya nilai yang tinggi menunjukkan bahwa model kurang mampu dalam memprediksi data.

6.2 Tinjauan Empiris

6.2.1 An autoencoder-based deep learning model for solving the sparsity issues of Multi-Criteria Recommender System (Rajput et al., 2024)

Pada penelitian ini, penulis membuat sebuah sistem rekomendasi menggunakan *autoencoder* dan faktorisasi matriks menggunakan *singular value decomposition*. Tujuan penulis melakukan penelitian ini adalah untuk mengevaluasi performa dari sistem rekomendasi yang menggunakan *autoencoder* dan faktorisasi matriks dan mengukur seberapa berkurangnya *data sparsity* setelah metodologi selesai diimplementasikan. Penulis menggunakan *autoencoder* untuk mengubah data menjadi representasi laten. Setelah itu dilakukan

faktorisasi matriks terhadap representasi laten tersebut menggunakan *singular value decomposition*. Data yang digunakan pada penelitian ini adalah dataset *Yahoo! Movies multi-criteria* yang berisi data peringkat multi-kriteria yang diberikan oleh pengguna untuk film. Pengujian dilakukan menggunakan *mean squared error* (MSE) dan *root mean squared error* (RMSE). Hasil yang didapatkan untuk 100 *epoch* adalah MAE sebesar 0.3350 dan RMSE sebesar 0.4897.

6.2.2 Sistem Rekomendasi Suku Cadang Berdasarkan Item Based Filtering (Wibisono et al., 2021)

Pada penelitian ini, penulis membangun sebuah sistem rekomendasi untuk pemilihan suku cadang. Metode sistem rekomendasi yang digunakan oleh penulis adalah *item-based collaborative filtering* dengan faktorisasi matriks menggunakan *singular value decomposition*. Data yang digunakan pada penelitian ini adalah data rating yang diberikan oleh pengguna untuk item dengan rentang nilai rating dari 1 sampai 5. SVD digunakan untuk mendekomposisi matriks rating dan mereduksi dimensinya untuk mengurangi efek “noise” dari data dengan *sparsity* tinggi. Pengujian dilakukan menggunakan *mean squared error* (MSE), *root mean squared error* (RMSE), dan *fraction of concordant pairs* (FCP). Hasil yang didapatkan adalah MAE sebesar 1.2752, RMSE sebesar 1.4882, dan FCP sebesar 0.4947.


6.2.3 Implementation of Dimensionality Reduction with SVD to Improve Rating Prediction in Recommender System (Mu’afa & Baizal, 2022)

Pada penelitian ini, penulis membangun sistem rekomendasi K-Means dan *singular value decomposition* untuk sistem rekomendasi film. Data yang digunakan pada penelitian ini adalah MovieLens 1M yang berisi 1.000.209 rating dari 6.040 pengguna untuk 3.706 film. Nilai rentan dari rating adalah 1 – 5. Metode K-Means digunakan untuk mengelompokkan pengguna dan matriks *utility*. Selanjutnya SVD dilakukan terhadap matriks *utility* untuk mendekomposisi dan mereduksi dimensi dari matriks. *Similarity* dicari antar *cluster* yang ada dan digunakan untuk melakukan prediksi rating untuk memberikan rekomendasi. Pengujian dilakukan dengan membandingkan performa antar K-Means saja dan K-Means dengan SVD menggunakan *root mean squared error* (RMSE). Hasil pengujian yang didapatkan RMSE sebesar 0.896 untuk K-Means saja dengan nilai $k = 50$ dan sebesar 0.835 untuk K-Means dengan SVD untuk nilai $k = 40$.

7. Metodologi Penelitian

7.1 Desain Sistem

Sistem rekomendasi yang akan dikembangkan menggunakan model *Variational Autoencoder* (VAE) dan metode *Regularized Singular Value Decomposition* (RSVD). Pembuatan sistem dimulai dengan mengumpulkan data yang akan digunakan untuk melatih model. Data yang telah dikumpulkan ada dilakukan diberikan beberapa tahap pemrosesan awal sebelum ke tahap selanjutnya. VAE akan diberikan masukan berupa matriks interaksi antara pengguna dengan film dan menghasilkan representasi laten dari masukan tersebut. Representasi laten tersebut akan didekomposisi menggunakan RSVD. Hasil dekomposisi ini akan dicari produknya dan menghasilkan rekonstruksi dari representasi laten yang akan diberikan kembali ke VAE untuk melakukan rekonstruksi dari matriks masukan.



Gambar 7.1 Diagram Alir Desain Sistem

7.2 Pengumpulan Data

Data yang digunakan merupakan data yang didapat secara sekunder dari situs web grouplens.org yang berjudul “movielens 100k”. Data movielens 100k berisikan beberapa file yaitu links.csv, movies.csv, tags.csv, dan ratings.csv. File yang akan digunakan pada penelitian ini adalah file ratings.csv yang berisikan 100.000 data rating yang diberikan oleh pengguna kepada film dan movies.csv yang berisikan 10.000 data film. Data rating memiliki beberapa kolom yaitu userId yang menandai id dari pengguna, movieId yang menandai id dari film, rating yang menandai penilaian yang diberikan, dan timestamp yang menandai waktu penilaian diberikan. Contoh untuk data *rating* terdapat pada tabel 7.1. Data film memiliki kolom movieId yang menandai id dari film, *title* yang berisi judul dan tahun keluarnya film, dan *genres* yang berisi genre dari film. Contoh untuk data film terdapat pada tabel 7.2.

Tabel 7.1 Contoh Data Rating

userId	MovieId	rating	timestamp
1	1	4.0	964982703
1	3	4.0	964981247
1	6	4.0	964982224
1	47	5.0	964983815
1	50	5.0	964982931

Tabel 7.2 Contoh Data Film

movieId	title	genres
0	Toy Story (1995)	Adventure Animation Children Comedy Fantasy
1	Jumanji (1995)	Adventure Children Fantasy
2	Grumpier Old Men (1995)	Comedy Romance
3	Waiting to Exhale (1995)	Comedy Drama Romance
4	Father of the Bride Part II (1995)	Comedy

7.3 Perancangan Model

Perancangan model dilakukan dalam beberapa tahapan yaitu *prerprocessing* data, pengembangan model *Variational Autoencoder* (VAE) dan dekomposisi menggunakan *Regularized Singular Value Decomposition* (RSVD). Diagram alir dari perancangan model dapat dilihat pada gambar 7.2.

**Gambar 7.2** Diagram Alir Perancangan Model


7.3.1 Preprocessing Data

Preprocessing data dimulai dengan menghilangkan atribut dari data yang tidak akan digunakan yaitu atribut “*timestamp*” karena pada penelitian ini tidak memperhitungkan kapan sebuah rating diberikan oleh pengguna. Selanjutnya data dalam bentuk tabel akan diubah menjadi matriks *sparse* dimana setiap kolom akan merepresentasikan film dan setiap baris akan merepresentasikan pengguna. Sel pada

matriks merepresentasikan rating yang diberikan oleh pengguna kepada film misalkan nilai pada baris i kolom j adalah nilai rating yang diberikan oleh pengguna ke- i untuk film ke- j . Contoh dari matriks *sparse* terdapat pada tabel 7.3.


Tabel 7.3 Contoh Matriks *Sparse*

	1	2	3	4	5	...
1	4.0	0.0	4.0	0.0	0.0	...
2	0.0	0.0	0.0	0.0	0.0	...
3	0.0	0.0	0.0	0.0	0.0	...
4	0.0	0.0	0.0	0.0	0.0	...
...	...	...	...	...	...	...



Gambar 7.3 Diagram Alir Preprocessing Data


Proses pemisahan data dilakukan menggunakan teknik holdout, di mana sebagian nilai akan dihapus dari dataset dan digunakan sebagai data uji. Dalam hal ini, data akan dibagi menjadi 80% data latih dan 20% data uji. Ini berarti 20% dari nilai rating film yang tersedia dalam dataset akan dihilangkan sementara dari data asli dan disisihkan sebagai data uji. Sisa 80% data yang masih mengandung nilai rating akan digunakan sebagai data latih. Dengan ini, model akan dilatih menggunakan data yang sudah dipecah, sementara data uji yang berisi nilai rating yang sebelumnya dihilangkan akan digunakan untuk menguji dan mengevaluasi kinerja model pada data yang belum pernah dilihat selama pelatihan. Gambaran dari pemisahan data terdapat pada gambar 7.4.



Gambar 7.4 Ilustrasi Proses Pemisahan Data

7.3.2 Pengembangan Model Variational Autoencoder

Variational Autoencoder (VAE) akan digunakan untuk menghasilkan representasi laten dari matriks rating. VAE akan diberikan data masukan yaitu matriks rating yang sudah dibagi menjadi data latih. Lapisan *encoder* pada VAE akan menerima data dan menghasilkan rata-rata dan *log-variance* dari distribusi. Lapisan *sampling* akan mengambil sampel dari distribusi ini dan menyimpannya sebagai representasi laten dari data masukan. Terakhir lapisan *decoder* menggunakan representasi laten untuk merekonstruksi data masukan. VAE akan dilatih dan dinilai menggunakan fungsi *loss* pada rumus (5). Fungsi *loss* VAE menghitung dua hal yaitu similaritas antara data masukan dengan data rekonstruksi dan divergensi antara distribusi data masukan dengan distribusi yang dibuat oleh lapisan *encoder*.



Gambar 7.5 Diagram Alir Pengembangan VAE

Hyperparameter tuning akan dilakukan untuk mencari model VAE yang optimal. Adapun beberapa *hyperparameter* yang akan diuji coba adalah jumlah layer, jumlah *neuron* pada layer, fungsi aktivasi, jumlah *epoch*, dan *learning rate*. Teknik *hyperparameter tuning* yang akan digunakan adalah *grid search* yang mencoba semua kombinasi dari nilai-nilai *hyperparameter* yang ditentukan. Kombinasi *hyperparameter* yang menghasilkan *loss* terendah akan dianggap sebagai model yang optimal.

7.3.3 Dekomposisi RSVD

Regularized Singular Value Decomposition akan digunakan untuk mendekomposisi matriks representasi laten Z yang didapatkan dari lapisan *encoder* pada VAE. Matriks Z memiliki dimensi $m \times n$ dimana m adalah jumlah sampel atau jumlah data masukan dan n adalah dimensi laten. Selanjutnya akan diinisialisasikan matriks faktor U dengan ukuran $m \times k$, V dengan ukuran $n \times k$, dan Σ dengan ukuran $k \times k$ dimana k adalah jumlah faktor laten, m adalah jumlah baris Z , dan n adalah jumlah kolom Z . Matriks-matriks faktor akan diubah

nilainya menggunakan fungsi *loss* yang merupakan kombinasi dari kesalahan rekonstruksi dan penalti regularisasi L2 yang terlihat pada rumus 8. Optimasi dilakukan menggunakan *Stochastic Gradient Descent* untuk meminimalkan fungsi *loss*. Untuk setiap parameter matriks faktor akan dihitung *loss* gradiennya dan nilainya akan diperbarui berdasarkan nilai gradien yang sudah dihitung. Optimasi dilakukan secara iteratif hingga mencapai konvergensi.

7.4 Perancangan Sistem

Sistem rekomendasi film akan dirancang dalam bentuk aplikasi berbasis web. Pengguna dapat melakukan beberapa hal dalam sistem seperti registrasi akun, melakukan *login*, melihat data film, mencari film, mendapatkan rekomendasi film, dan memberikan rating untuk film. Rekomendasi film yang didapatkan oleh pengguna adalah film-film yang diprediksi oleh sistem rekomendasi akan diberikan rating yang tinggi oleh pengguna dan belum diberikan rating oleh pengguna. Model rekomendasi akan digunakan untuk melakukan rekonstruksi matriks rating yang dimana rekonstruksi tersebut akan mengisi nilai-nilai yang kosong dalam matriks yang merupakan prediksi rating pengguna kepada sebuah film. Film yang direkomendasikan oleh sistem akan ditampilkan pada bagian rekomendasi film beserta data-data film bersangkutan seperti judul, tahun rilis, dan genre dari film.

Sistem rekomendasi akan dirancang dengan bagian *frontend* dan *backend* yang terpisah. Bagian *frontend* dirancang sebagai sarana untuk pengguna berinteraksi dengan sistem. *Frontend* berguna untuk menampilkan data kepada pengguna seperti data film dan rekomendasi film, juga berfungsi sebagai tempat penginputan data pada saat registrasi akun, *login*, dan memberikan rating untuk film. Bagian *backend* dirancang sebagai pengatur masuk keluarnya data pada sistem. *Backend* berfungsi untuk memberikan data seperti data film dan data rekomendasi ke *frontend* agar dapat diperlihatkan kepada pengguna. Selain itu, bagian *backend* juga berguna untuk memproses data yang dikirimkan oleh *frontend* seperti data kredensial dan data rating yang diberikan pengguna, dan juga sebagai tempat disimpan dan dijalanakannya model untuk memberikan rekomendasi.

Sistem rekomendasi juga memerlukan tempat penyimpanan untuk menyimpan semua data film, data pengguna, data film, dan lainnya. Basis data relasional akan digunakan untuk menyimpan data-data tersebut. Bagian *backend* dari sistem bertugas dalam berinteraksi dengan basis data. *Backend* akan melakukan operasi *create*, *read*, *update*, dan *delete* (CRUD) dimana *backend* dapat mengisi data, mengambil data, memperbarui data, dan menghapus data sesuai dengan keperluan.

7.5 Implementasi Sistem

Model rekomendasi yang menggabungkan *Variational Autoencoder* (VAE) dan *Regularized Singular Value Decomposition* akan diimplementasikan menggunakan *library* seperti *pandas*, *numpy*, *tensorflow*, *scikit learn*, dan lainnya. *Library pandas* dan *numpy* digunakan dalam melakukan *preprocessing* data yang digunakan dalam pembuatan model. *Library tensorflow* dan *scikit learn* digunakan untuk membangun, melatih, dan menguji model. *Library* tambahan seperti *Pickle* digunakan untuk menyimpan model yang sudah jadi dalam bentuk file yang akan digunakan oleh bagian *backend* untuk menghasilkan rekomendasi.

Implementasi sistem rekomendasi dimulai dengan pembuatan bagian *backend* yang dikembangkan menggunakan *framework* berbasis *Python* seperti *Flask* atau *FastAPI*. *Framework* ini akan digunakan untuk membuat dan mengatur sebuah *Application Programming Interface* (API) yang akan digunakan oleh *frontend*. API akan menyediakan *endpoint* untuk fungsi-fungsi utama dari sistem seperti registrasi, pengambilan data film, penyimpanan rating, dan pengambilan rekomendasi.


Penyimpanan data-data sistem rekomendasi akan dilakukan dalam basis data relasional seperti *MySQL* atau *PostgreSQL* yang menyimpan data dalam bentuk tabel-tabel yang berhubungan relasional. Sebuah *Object-Relational Mapper* (ORM) seperti *SQLAlchemy* akan digunakan untuk mempermudah interaksi antara *backend* dengan basis data. ORM dapat memetakan kelas dalam *Python* ke tabel dalam basis data sehingga mempermudah manipulasi data dengan perintah berbasis objek, tanpa menulis perintah SQL secara manual.

Pada bagian *frontend*, akan digunakan *framework* seperti *ReactJS* untuk membangun antarmuka yang interaktif dan responsif. Antarmuka ini akan menampilkan data-data film, data detail untuk setiap film, serta rekomendasi yang didapatkan dari *endpoint* API. Bagian *frontend* juga menyediakan fitur-fitur lain seperti registrasi dan *login*, pencarian film berdasarkan judul, genre, atau tahun rilis, dan penginputan rating untuk film.

7.6 Evaluasi Sistem Rekomendasi

Evaluasi performa dari model dalam menghasilkan rekomendasi diuji menggunakan semua data rating yang sudah diberlakukan metode *holdout* dimana sebagian rating pengguna dihilangkan. Nilai rating yang dihilangkan ini adalah data uji yang akan digunakan untuk mengevaluasi performa dari model. Data akan diberikan kepada VAE agar lapisan *encoder* dapat menghasilkan representasi laten Z . Hasil representasi laten akan didekomposisi RSVD menghasilkan matriks U , V , dan Σ . Produk dari $U\Sigma V^T$

akan menghasilkan rekonstruksi representasi laten $\hat{Z}$. Matriks $\hat{Z}$ diberikan kepada lapisan *decoder* pada VAE untuk merekonstruksi matriks *rating*. Perbedaan antara nilai rating yang dihilangkan dengan nilai rating yang diisi oleh model melalui proses rekonstruksi akan dihitung menggunakan MSE dan RMSE. Nilai MSE dan RMSE yang lebih rendah menunjukkan prediksi yang lebih akurat. Gambar diagram alir pengujian model terdapat pada gambar 7.6.



Gambar 7.6 Diagram Alir Pengujian Model

Pengujian untuk sistem rekomendasi dilakukan dengan metode *blackbox testing* yang berfokus pada fungsi-fungsi eksternal sistem tanpa mengetahui detail program atau algoritma sistem. Pengujian dilakukan untuk memastikan fitur-fitur utama seperti registrasi, *login*, menampilkan film, menampilkan rekomendasi, pencarian film, pemberian rating film dan fitur lainnya berjalan sebagaimana mestinya. Pengujian dimulai dengan membuat beberapa kasus yang berisikan tindakan yang dilakukan dan hasil yang diharapkan. Selanjutnya tindakan yang ada pada kasus akan dilakukan di dalam sistem dan penilaian untuk pengujian adalah perbandingan antara hasil yang diharapkan pada kasus dan yang dihasilkan oleh sistem. Hasil sistem yang mendekati atau sama dengan hasil yang diharapkan pada kasus menandakan bahwa sistem berfungsi dengan baik.

8. Jadwal Pelaksanaan Penelitian

Tabel 8.1 Rancangan Jadwal Pelaksanaan Penelitian

No.	Kegiatan	Bulan					
		1	2	3	4	5	6
1.	Desain Sistem						
2.	Pengumpulan Data						
3.	Perancangan Model						
4.	Perancangan Sistem						
5.	Implementasi Sistem						
6.	Evaluasi Sistem Rekomendasi						
7.	Penulisan Laporan Penelitian						

DAFTAR PUSTAKA

- Ayu, D., Safitri, N., Helilintar, R., & Wahyuniar, L. S. (2021). Sistem Rekomendasi Skincare Menggunakan Metode Content-Based Filtering dan Algoritma Apriori. *Prosiding SEMNAS INOTEK (Seminar Nasional Inovasi Teknologi)*, 5(2), 242–248. <https://doi.org/10.29407/INOTEK.V5I2.1136>
- Cai, B., Yang, S., Gao, L., & Xiang, Y. (2023). Hybrid variational autoencoder for time series forecasting. *Knowledge-Based Systems*, 281, 111079. <https://doi.org/10.1016/J.KNOSYS.2023.111079>
- Hancock, D., Slee, J., & Wunsch-Vincent, S. (2024, March 28). *Resurgence of Global Cinema: 2022 and 2023 witness forceful comeback but still shy of pre-pandemic norms*. https://www.wipo.int/global_innovation_index/en/gii-insights-blog/2024/global-cinema.html
- Hodson, T. O. (2022). Root-mean-square error (RMSE) or mean absolute error (MAE): when to use them or not. *Geoscientific Model Development*, 15(14), 5481–5487. <https://doi.org/10.5194/GMD-15-5481-2022>
- Mu'afa, M. N., & Baizal, Z. K. A. (2022). Implementation of Dimensionality Reduction with SVD to Improve Rating Prediction in Recommender System. *Journal of Computer System and Informatics (JoSYC)*, 3(4), 544–551. <https://doi.org/10.47065/JOSYC.V3I4.2110>
- Nugroho, F., & Rahayu, M. I. (2020). SISTEM REKOMENDASI PRODUK UKM DI KOTA BANDUNG MENGGUNAKAN ALGORITMA COLLABORATIVE FILTERING. *Jurnal Riset Sistem Informasi Dan Teknologi Informasi (JURSISTEKNI)*, 2(3), 23–31. <https://doi.org/10.52005/JURSISTEKNI.V2I3.63>
- Rajput, I. S., Tewari, A. S., & Tiwari, A. K. (2024). An autoencoder-based deep learning model for solving the sparsity issues of Multi-Criteria Recommender System. *Procedia Computer Science*, 235, 414–425. <https://doi.org/10.1016/J.PROCS.2024.04.041>
- Sutjiningtyas, S., Arofa Dharmawan, A., & Penulis Korespondensi, E. (2022). Rancang Bangun Sistem Rekomendasi Produk Sepatu pada Toko Online Menggunakan Metode User-Base Collaborative Filtering. *Bulletin of Information Technology (BIT)*, 3(2), 143–148. <https://doi.org/10.47065/BIT.V3I2.288>

- Wang, P., Lei, Y., Ying, Y., & Zhou, D. X. (2024). Differentially private stochastic gradient descent with low-noise. *Neurocomputing*, 585, 127557. <https://doi.org/10.1016/J.NEUCOM.2024.127557>
- Wibisono, C., Surya, L., #2, H., & Widyaya, J. E. (2021). Sistem Rekomendasi Suku Cadang Berdasarkan Item Based Filtering. *Jurnal Teknik Informatika Dan Sistem Informasi*, 7(1), 2443–2229. <https://doi.org/10.28932/JUTISI.V7I1.3036>