

**IMPLEMENTASI VARIATIONAL AUTOENCODER DAN  
REGULARIZED SINGULAR VALUE DECOMPOSITION PADA SISTEM  
REKOMENDASI FILM**

**SKRIPSI**



**IDA BAGUS GEDE BASUDEWA WEDA**

**NIM.2208561077**

**PROGRAM STUDI INFORMATIKA  
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM  
UNIVERSITAS UDAYANA  
JIMBARAN**

**2026**

**IMPLEMENTASI VARIATIONAL AUTOENCODER DAN  
REGULARIZED SINGULAR VALUE DECOMPOSITION PADA SISTEM  
REKOMENDASI FILM**

**SKRIPSI**



**IDA BAGUS GEDE BASUDEWA WEDA  
NIM.2208561077**

**PROGRAM STUDI INFORMATIKA  
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM  
UNIVERSITAS UDAYANA  
JIMBARAN  
2026**

# BAB I

## PENDAHULUAN

### 1.1 Latar Belakang

Industri perfilman mengalami peningkatan yang signifikan pada jumlah film yang diproduksi setelah terjadinya penurunan produksi yang disebabkan oleh terjadinya pandemi COVID-19 pada tahun 2020. Pada tahun 2021 produksi film meningkat sebesar 40% dan pada tahun 2022 meningkat sebesar 15%. Keuntungan yang diraup dari Global box office juga meningkat pada tahun 2022 meningkat sebesar 21,8% dan pada tahun 2023 meningkat sebesar 29,4% (Hancock et al., 2024). Peningkatan kuantitas film yang diproduksi dan keuntungan yang didapatkan akan memperbanyak film yang tersedia. Banyaknya film yang tersedia akan memberikan pilihan yang banyak kepada penonton, tetapi juga memberikan tantangan yaitu menemukan film yang sesuai dengan preferensi mereka. Sistem rekomendasi dapat digunakan untuk mengatasi tantangan ini.

Sistem rekomendasi merupakan sistem yang berfungsi untuk memperkirakan dan memberikan informasi yang sekiranya menarik untuk seorang pengguna. Sistem rekomendasi menggunakan berbagai metode untuk memberikan saran produk berdasarkan preferensi dan kebutuhan pengguna seperti content-based filtering, collaborative filtering, dan metode hybrid. Metode content-based filtering bekerja dengan menganalisis atribut atau fitur dari item-item yang disukai oleh pengguna dan kemudian merekomendasikan item lain yang memiliki kemiripan atribut (Ayu et al., 2021). Metode collaborative filtering dapat dibagi menjadi dua kategori yaitu memory-based dan model-based. Kategori memory-based menggunakan tingkat similaritas untuk memberikan prediksi dengan mencari asosiasi antara pengguna dengan item (Rajput et al., 2024). Kategori memory-based dapat dikategorikan lagi menjadi item-based dan user-based. Item-based menganalisis bagaimana pengguna menilai suatu item dan mencari item dengan penilai yang mirip. User-based mencari pengguna yang mirip berdasarkan penilaian yang diberikan dan merekomendasikan item yang pengguna mirip sudah sukai ke pengguna target. Model-based menggunakan matriks pengguna-item

sebagai data untuk membangun dan melatih sebuah model yang dapat memprediksi penilaian pengguna terhadap suatu item.

Salah satu tantangan utama dalam sistem rekomendasi adalah data sparsity. Data sparsity merujuk pada situasi di mana interaksi antara pengguna dan item sangat sedikit atau jarang. Dalam sistem rekomendasi berbasis matriks, ini berarti matriks pengguna-item memiliki banyak nilai kosong atau tidak diketahui. Hal ini menyulitkan model untuk menemukan pola yang cukup kuat untuk memberikan rekomendasi yang akurat. Misalnya, dalam layanan streaming dengan ribuan film, kebanyakan pengguna mungkin hanya menonton atau memberikan rating pada sebagian kecil dari film yang tersedia, menyebabkan matriks menjadi sangat jarang terisi.

Penelitian terkait sistem rekomendasi telah banyak dilakukan untuk mengatasi masalah data sparsity dan meningkatkan akurasi prediksi. Rajput et al. (2024) menggunakan penggabungan standard autoencoder dan faktorisasi matriks dengan singular value decomposition (SVD) untuk mengatasi masalah sparsity dalam sistem rekomendasi multi-kriteria, dengan hasil MAE sebesar 0.3350 dan RMSE sebesar 0.4897. Wibisono et al. (2021) mengembangkan sistem rekomendasi menggunakan item-based collaborative filtering dengan SVD yang terbukti mampu mereduksi dimensi matriks rating dan mengurangi noise pada data sparse, dengan hasil MAE sebesar 1.2752 dan RMSE sebesar 1.4882. Selain itu, Mu'afa dan Baizal (2022) menunjukkan bahwa penggabungan SVD dengan metode lain mampu meningkatkan akurasi prediksi rating dengan RMSE sebesar 0.835 dibandingkan 0.896 tanpa SVD. Penelitian-penelitian ini secara konsisten menunjukkan potensi penggabungan faktorisasi matriks berbasis SVD dengan metode lain untuk meningkatkan performa sistem rekomendasi. Namun, seluruh penelitian tersebut menggunakan standard autoencoder, bukan Variational Autoencoder (VAE), dan SVD tanpa regularisasi sehingga masih terdapat gap penelitian yang belum dieksplorasi.

Berdasarkan gap tersebut, penelitian ini mengajukan pendekatan yang menggabungkan Variational Autoencoder (VAE) dan Regularized Singular Value Decomposition (RSVD). VAE dipilih karena memiliki karakteristik yang sesuai

untuk sistem rekomendasi, sifat Bayesian-nya memungkinkan VAE menangani data sparse dan kompleks seperti data interaksi pengguna-item secara lebih tepat karena ketidakpastian diperhitungkan dalam proses inferensi, dan VAE mempelajari representasi laten sebagai distribusi probabilistik sehingga menghasilkan latent space yang lebih terstruktur dibandingkan standard autoencoder (Liang et al., 2024; Bobadilla et al., 2023). Namun, pelatihan VAE pada data collaborative filtering berisiko mengalami posterior collapse, yaitu kondisi di mana model mengabaikan struktur ruang laten dan hanya mengandalkan decoder sehingga representasi laten menjadi tidak informatif (Wang et al., 2025). Untuk mengatasi hal ini, penelitian ini menerapkan KL annealing yaitu sebuah teknik yang menaikkan bobot  $\beta$  pada KL divergence secara bertahap selama pelatihan agar model terlebih dahulu mempelajari rekonstruksi sebelum tekanan regularisasi diberikan sepenuhnya (Liang et al., 2024). Di sisi lain, SVD standar pada sistem rekomendasi sering kali menemui kendala ketika dihadapkan pada data yang sangat sparse. SVD standar cenderung mengalami overfitting karena model berusaha menghafal data latih sehingga menghasilkan generalisasi yang buruk pada data yang belum pernah dilihat sebelumnya. Penerapan regularisasi pada RSVD mengatasi kelemahan ini dengan memberikan penalti pada parameter latent factor pengguna dan item, yang secara signifikan mengurangi risiko overfitting dan membuat model lebih stabil serta akurat dalam memprediksi rating pada matriks yang jarang terisi (Darma Putra & Santiyasa, 2025). Kombinasi spesifik VAE dan RSVD ini belum pernah dieksplorasi dalam penelitian sebelumnya, sehingga penelitian ini berkontribusi dalam mengisi gap tersebut.

Pendekatan hybrid yang menggabungkan dua model dengan karakteristik berbeda terbukti mampu mengatasi keterbatasan masing-masing model secara individual dalam sistem rekomendasi, karena setiap model dapat saling melengkapi kelemahan yang lain (Sami et al., 2024). Dalam penelitian ini, VAE dan RSVD memiliki karakteristik yang saling komplementer, VAE unggul dalam menangkap pola preferensi pengguna yang kompleks dan non-linear melalui representasi probabilistik di ruang laten (Liang et al., 2024; Bobadilla et al., 2023), namun prediksinya dapat kurang stabil pada data yang sangat sparse karena bergantung

pada sampling dari distribusi laten. Sebaliknya, RSVD menghasilkan prediksi yang lebih stabil melalui dekomposisi bias dan faktor laten yang terregularisasi (Darma Putra & Santiyasa, 2025), namun terbatas dalam menangkap hubungan non-linear antar pengguna dan item. Dengan menggabungkan prediksi keduanya melalui weighted average ensemble penelitian ini bertujuan memanfaatkan kekuatan representasi probabilistik VAE sekaligus kestabilan prediksi RSVD, sehingga diharapkan menghasilkan sistem rekomendasi yang lebih akurat dibandingkan masing-masing model secara mandiri.

Berdasarkan hal tersebut, penelitian ini bertujuan untuk mengembangkan dan mengevaluasi sistem rekomendasi film yang menggabungkan VAE dan RSVD menggunakan dataset MovieLens 100k, serta mengukur performanya menggunakan metrik *mean squared error* (MSE), *root mean squared error* (RMSE), dan *mean absolute error* (MAE).

## 1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijabarkan, rumusan masalah pada penelitian ini adalah sebagai berikut:

- a. Bagaimana performa sistem rekomendasi dengan *variational autoencoder* dan *regularized singular value decomposition* dalam menghasilkan rekomendasi?
- b. Bagaimana pengembangan model sistem rekomendasi *variational autoencoder* dan *regularized singular value decomposition*?
- c. Bagaimana model yang optimal untuk sistem rekomendasi dengan *variational autoencoder* dan *regularized singular value decomposition*?
- d. Bagaimana kinerja implementasi sistem rekomendasi yang menggunakan *variational autoencoder* dan *regularized singular value decomposition*?

## 1.3 Batasan Masalah

Terdapat beberapa batasan permasalahan dalam penelitian ini:

- a. Data didapatkan secara sekunder dari situs web grouplens.org yang berjudul “movielens 100k”.
- b. Pengguna tidak dapat menonton film secara langsung pada sistem.

- c. Sistem hanya dapat memberikan rekomendasi item yang terdapat pada data.

#### 1.4 Tujuan Penelitian

Berdasarkan latar belakang dan rumusan masalah yang telah dijabarkan, tujuan dari penelitian ini adalah sebagai berikut:

- d. Mengetahui performa sistem rekomendasi yang menggunakan *variational autoencoder* dan *regularized singular value decomposition* dalam menghasilkan rekomendasi.
- e. Mengetahui bagaimana pengembangan model sistem rekomendasi *variational autoencoder* dan *regularized singular value decomposition*
- f. Mengetahui model yang optimal untuk sistem rekomendasi dengan *variational autoencoder* dan *regularized singular value decomposition*.
- g. Mengetahui kinerja implementasi sistem rekomendasi yang menggunakan *variational autoencoder* dan *regularized singular value decomposition*.

#### 1.5 Manfaat Penelitian

Manfaat dari hasil penelitian ini adalah:

- a. Bagi penonton, dapat dengan mudah mendapatkan rekomendasi yang sesuai dengan preferensi mereka.
- b. Bagi pembuat film, Film yang dibuat dapat direkomendasikan kepada pengguna sesuai dengan preferensi mereka.

#### 1.6 Sistematika Penulisan

Untuk memberikan gambaran yang jelas dan menyeluruh mengenai penyusunan Tugas Akhir ini, maka penulisan dibagi menjadi lima bab dengan sistematika sebagai berikut:

#### **BAB I PENDAHULUAN**

Bab ini menguraikan kerangka dasar penelitian yang meliputi latar belakang masalah mengenai data sparsity pada sistem rekomendasi film, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, serta sistematika penulisan yang digunakan dalam penyusunan tugas akhir.

#### **BAB II TINJAUAN PUSTAKA**

Bab ini membahas landasan teori dan tinjauan empiris dari penelitian-penelitian terdahulu yang relevan. Landasan teori yang diuraikan mencakup konsep dasar sistem rekomendasi, *Collaborative Filtering*, *Variational Autoencoder* (VAE), *Regularized Singular Value Decomposition* (RSVD), serta metrik evaluasi pengujian (seperti MSE, RMSE, dan MAE). Bab ini menjadi dasar pijakan untuk perancangan model yang diusulkan.

### **BAB III METODOLOGI PENELITIAN**

Bab ini menjelaskan tahapan, analisis, dan perancangan yang dilakukan dalam penelitian. Pembahasan di dalamnya meliputi desain sistem secara umum, teknik pengumpulan data sekunder (dataset MovieLens 100k), perancangan model (preprocessing data, pengembangan model VAE, dan dekomposisi dengan RSVD), perancangan antarmuka sistem rekomendasi berbasis web, serta rancangan skenario evaluasi kinerja sistem.

### **BAB IV HASIL DAN PEMBAHASAN**

Bab ini memaparkan secara detail hasil dari implementasi sistem dan pengujian model yang telah dirancang pada bab sebelumnya. Pembahasan difokuskan pada analisis performa sistem rekomendasi hasil penggabungan arsitektur VAE dan RSVD, perbandingan metrik evaluasi untuk mengukur akurasi prediksi, serta hasil implementasi antarmuka (frontend dan backend) sistem rekomendasi film.

### **BAB V SIMPULAN DAN SARAN**

Bab ini berisi kesimpulan akhir yang ditarik dari hasil analisis dan pembahasan untuk menjawab rumusan masalah penelitian. Selain itu, pada bab ini juga dikemukakan saran-saran yang konstruktif untuk mengatasi keterbatasan yang ada serta sebagai bahan pertimbangan bagi pengembangan sistem atau penelitian sejenis di masa yang akan datang.



## BAB II

### TINJAUAN PUSTAKA

#### 2.1 Tinjauan Teori

##### 2.1.1 Sistem Rekomendasi

Sistem rekomendasi merupakan sistem yang berfungsi untuk memperkirakan dan memberikan informasi yang sekiranya menarik untuk seorang pengguna (Nugroho & Rahayu, 2020). Sistem rekomendasi bekerja dengan menganalisis data pengguna, seperti riwayat pembelian, tontonan, dan interaksi mereka dengan platform digital. Berdasarkan data tersebut, sistem rekomendasi dapat memprediksi apa yang disukai dan dibutuhkan pengguna, dan kemudian memberikan rekomendasi yang dipersonalisasi. Rekomendasi yang diberikan oleh sistem dapat digunakan oleh pengguna untuk mempertimbangkan apa yang harus mereka lakukan, seperti membeli barang atau menonton pertunjukan. Sistem ini banyak digunakan dalam berbagai industri, seperti *e-commerce*, *media streaming*, media sosial, dan lainnya.

##### 2.1.2 Collaborative Filtering

*Collaborative filtering* adalah teknik yang digunakan dalam sistem rekomendasi untuk memberikan saran item kepada pengguna berdasarkan preferensi pengguna lain yang serupa (Sutjiningtyas et al., 2022). Sederhananya, sistem ini mencari pengguna yang memiliki selera yang sama dengan pengguna yang ingin mendapatkan rekomendasi, dan kemudian merekomendasikan item yang disukai oleh pengguna-pengguna tersebut. Contohnya, di situs web *e-commerce*, *collaborative filtering* dapat digunakan untuk merekomendasikan produk kepada pengguna berdasarkan produk yang telah mereka beli atau lihat sebelumnya, serta produk yang dibeli oleh pengguna lain yang memiliki profil serupa.

*Collaborative filtering* dapat dibagi menjadi dua kategori yaitu *memory-based* dan *model-based*. Kategori *memory-based* menggunakan tingkat similaritas untuk memberikan prediksi dengan mencari asosiasi antara pengguna dengan *item* (Rajput et al., 2024). Kategori *memory-based* dapat dikategorikan lagi menjadi *item-based* dan *user-based*. *Item-based* menganalisis bagaimana pengguna menilai

suatu *item* dan mencari *item* dengan penilai yang mirip. *User-based* mencari pengguna yang mirip berdasarkan penilaian yang diberikan dan merekomendasikan item yang pengguna mirip sudah sukai ke pengguna target. *Model-based* menggunakan matriks pengguna-item sebagai data untuk membangun dan melatih sebuah model yang dapat memprediksi penilaian pengguna terhadap suatu item.

### 2.1.3 Variational Autoencoder (VAE)

Variational Autoencoder (VAE) adalah model generatif berbasis jaringan saraf tiruan yang mempelajari representasi laten dari data masukan sebagai distribusi probabilistik, bukan sebagai titik tetap di ruang laten (Liang et al., 2024). Berbeda dengan autoencoder standar yang memetakan setiap input ke satu titik laten, VAE memetakan input ke parameter distribusi Gaussian, yaitu rata-rata  $\mu$  dan log-varians  $\log(\sigma^2)$ , sehingga ruang laten menjadi kontinu dan terstruktur. VAE memodelkan data sebagai:

$$p(x, z) = p(x|z)p(z) \quad (1)$$

Keterangan:

- $x$  = data masukan
- $z$  = representasi laten
- $p(x|z)$  = probabilitas  $x$  diberikan  $z$
- $p(z)$  = prior dari  $z$ , diasumsi sebagai distribusi Gaussian standar  $N(0,1)$

Karena posterior sejati  $p(z|x)$  bersifat *intractable*, VAE mengaproksimasi posterior tersebut dengan distribusi variasional:

$$q(z|x) = N(z|\mu(x), \sigma(x)) \quad (2)$$

Keterangan:

- $\mu(x)$  = rata-rata yang dihasilkan *encoder*
- $\sigma(x)$  = varians yang dihasilkan *encoder*

Fungsi objektif VAE adalah *Evidence Lower Bound* (ELBO):

$$\mathcal{L} = E_{q(z|x)}[\log p(x|z)] - \beta \cdot KL(q(z|x)||p(z)) \quad (3)$$

Keterangan:

- $E_{q(z|x)}[\log p(x|z)]$  = *reconstruction loss*
- $\beta \cdot KL(q(z|x)||p(z))$  = KL divergence

Bagian pertama adalah *reconstruction loss* yang mengukur seberapa baik *decoder* merekonstruksi data dari  $z$ , dan bagian kedua adalah *KL divergence* yang meregularisasi distribusi laten agar mendekati prior Gaussian. *Hyperparameter*  $\beta$  mengontrol bobot antara dua komponen ini (Wang et al., 2025).

Untuk kasus *prior* Gaussian standar  $\mathcal{N}(0, I)$ , *KL divergence* antara distribusi posterior  $q(z | x)$  dan prior  $p(z)$  dapat dihitung sebagai:

$$L_{KL} = -\frac{1}{2} \sum_{j=1}^d (1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2) \quad (4)$$

Keterangan:

- $d$  = dimensi ruang laten
- $\mu_j$  = rata-rata dimensi ke- $j$  dari distribusi *posterior*
- $\sigma_j^2$  = varians dimensi ke- $j$  dari distribusi *posterior*

Pada penelitian ini, *reconstruction loss* dihitung hanya pada *rating* yang tersedia, mengabaikan sel kosong dalam matriks interaksi yang belum diberi *rating*. Pendekatan ini disebut *masked reconstruction loss* dan diformulasikan sebagai:

$$L_{recon} = (\sum_{\{(u,i) \in \Omega\}} (r_{ui} - \hat{r}_{ui})^2) / |\Omega| \quad (5)$$

Keterangan:

- $\Omega$  = himpunan pasangan *user item* yang memiliki *rating*
- $r_{ui}$  = *rating* asli
- $\hat{r}_{ui}$  = prediksi rekonstruksi *decoder*

Pendekatan *masked loss* mencegah model belajar dari nilai kosong yang bukan merupakan preferensi nyata pengguna, sehingga representasi laten yang dihasilkan lebih akurat mencerminkan pola interaksi yang sebenarnya. Total loss VAE pada penelitian ini adalah:

$$L_{VAE} = L_{recon} + \beta \cdot KL(q(z|x) || p(z)) \quad (6)$$

Untuk mencegah *posterior collapse* yaitu kondisi di mana model mengabaikan  $z$  dan hanya mengandalkan decoder (Wang et al., 2025), nilai  $\beta$  dinaikkan secara bertahap dari 0 menuju nilai target selama pelatihan menggunakan teknik KL annealing (Liang et al., 2024).

Sama seperti *autoencoder* pada umumnya, VAE memiliki tiga komponen utama (Liang et al., 2024):

- Lapisan *Encoder*

Lapisan *Encoder* berfungsi mengubah data masukan menjadi parameter distribusi laten. *Encoder* menerima vektor rating pengguna dan menghasilkan  $\mu$  dan  $\log(\sigma^2)$  dari distribusi Gaussian laten.

- Lapisan *Sampling*

Lapisan *Sampling* memungkinkan *backpropagation* melalui proses sampling menggunakan *reparameterization trick*. Sampel  $z$  diambil dari distribusi Gaussian menggunakan rumus:

$$z = \mu + \sigma \cdot \varepsilon \quad (7)$$

Keterangan:

- $\varepsilon \sim N(0, I)$  = sampel acak dari distribusi normal standar
- $\mu$  = rata-rata distribusi
- $\sigma$  = standar deviasi distribusi

- Lapisan *Decoder*

Lapisan Decoder merekonstruksi data dari representasi laten  $z$  menggunakan lapisan *dense* dengan fungsi aktivasi *sigmoid* untuk menghasilkan prediksi rating dalam rentang 0 - 1.

#### 2.1.4 Regularized Singular Value Decomposition (RSVD)

*Singular Value Decomposition* (SVD) merupakan teknik faktorisasi matriks yang memecah sebuah matriks menjadi komponen-komponen yang lebih sederhana. Dalam konteks sistem rekomendasi, SVD digunakan untuk mendekomposisi matriks rating pengguna-item menjadi representasi laten berdimensi rendah yang menangkap pola preferensi tersembunyi (Alshbanat et al., 2025). Matriks  $A$  berukuran  $m \times n$  yang didekomposisi dengan SVD dinyatakan sebagai:

$$A = U\Sigma V^T \quad (8)$$

Keterangan:

- $U$  = matriks ortogonal berukuran  $m \times r$  yang memuat vektor eigen dari  $M^T M$
- $\Sigma$  = matriks diagonal berukuran  $r \times r$  berisi nilai-nilai singular non-negatif
- $V^T$  = matriks ortogonal berukuran  $r \times n$  yang memuat vektor eigen dari  $MM^T$

Namun, SVD klasik tidak dapat diterapkan langsung pada matriks rating yang sparse karena memerlukan matriks lengkap. Untuk mengatasi hal ini sekaligus mencegah *overfitting*, diterapkan regularisasi L2 sehingga menghasilkan *Regularized Singular Value Decomposition* (RSVD). Selain itu, implementasi RSVD pada sistem rekomendasi diperkaya dengan *bias terms* berupa rata-rata global ( $\mu$ ), bias pengguna ( $b_u$ ), dan bias item ( $b_i$ ) untuk menangkap kecenderungan rating yang bersifat sistematis di luar faktor laten (Alshbanat et al., 2025). Prediksi rating dari pengguna  $u$  terhadap item  $i$  diformulasikan sebagai:

$$\hat{r} = \mu + b_u + b_i + (U\Sigma V^T)_{ui} \quad (9)$$

Keterangan:

- $\mu$  = rata-rata *rating* global
- $b_u$  = bias pengguna  $u$
- $b_i$  = bias *item*  $i$
- $(U\Sigma V^T)_{ui}$  = komponen faktor laten

Fungsi *loss* yang dioptimalkan menggunakan regularisasi L2 atau *Ridge Regularization* adalah:

$$Loss = \sum_{i,j} (Z_{ij} - \hat{r}_{ij})^2 + \lambda (\|U\|_F^2 + \|V\|_F^2) \quad (10)$$

Keterangan:

- $Z$  = matriks rating asli
- $\lambda$  = bobot penalti regularisasi
- $\|X\|_F^2$  = kuadrat norma *Frobenius* dari  $x$

Norma Frobenius dari matriks  $A$  berukuran  $m \times n$  dihitung sebagai:

$$\|A\|_F = \sqrt{(\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2)} \quad (11)$$

Keterangan:

- $a_{ij}$  = elemen baris ke- $i$  kolom ke- $j$  dari matriks  $A$

Untuk mengoptimalkan fungsi *loss*, digunakan metode *Stochastic Gradient Descent* (SGD) yang memperbarui parameter secara iteratif menggunakan informasi gradien dari satu data rating pada setiap langkah pembaruan (Alshbanat et al., 2025). Berbeda dengan *gradient descent* biasa yang menghitung gradien dari seluruh data sekaligus, SGD melakukan pembaruan hanya pada pasangan ( $u, i$ ) yang memiliki rating aktual ( $Z[u,i] > 0$ ), sehingga sel-sel kosong dalam matriks

*sparse* tidak mempengaruhi gradien. Aturan pembaruan untuk setiap parameter adalah:

$$U[u, k] \leftarrow U[u, k] + \eta \cdot (e_{ui} \cdot \Sigma[k, k] \cdot V[i, k] - \lambda \cdot U[u, k]) \quad (12)$$

$$V[i, k] \leftarrow V[i, k] + \eta \cdot (e_{ui} \cdot \Sigma[k, k] \cdot U[u, k] - \lambda \cdot V[i, k]) \quad (13)$$

$$\Sigma[k, k] \leftarrow \Sigma[k, k] + \eta \cdot (e_{ui} \cdot U[u, k] \cdot V[i, k]) \quad (14)$$

dimana  $\eta$  adalah *learning rate* dan error rekonstruksi  $e_{ui}$  didefinisikan sebagai:

$$e_{ui} = Z[u, i] - \hat{r}_{ui} \quad (15)$$

Terlihat pada rumus (11) dan (12) bahwa pembaruan  $U$  dan  $V$  mengandung suku penalti regularisasi  $\lambda$ , sedangkan pada rumus (13) pembaruan  $\Sigma$  tidak mengandung suku penalti tersebut. Keputusan mengenai penerapan regularisasi pada  $\Sigma$  serta strategi inisialisasinya dibahas lebih lanjut pada bagian metodologi.

### 2.1.5 Sistem Rekomendasi Hibrid

Sistem rekomendasi hibrid merupakan pendekatan yang menggabungkan dua atau lebih teknik rekomendasi untuk memanfaatkan kelebihan masing-masing teknik secara bersamaan (Sami et al., 2024). Pendekatan ini dilatarbelakangi oleh kenyataan bahwa setiap teknik rekomendasi tunggal memiliki keterbatasan tersendiri. Collaborative filtering rentan terhadap masalah cold-start dan data sparsity, sedangkan metode berbasis konten bergantung pada ketersediaan atribut item yang lengkap. Dengan menggabungkan beberapa teknik, sistem rekomendasi hibrid dapat saling menutupi kelemahan masing-masing sehingga menghasilkan prediksi yang lebih akurat (Sami et al., 2024).

Salah satu strategi hibridisasi yang umum digunakan adalah weighted hybridization, di mana prediksi akhir diperoleh dari kombinasi linear tertimbang (weighted linear combination) dari prediksi yang dihasilkan oleh masing-masing model penyusun. Pada strategi ini, setiap model diberi bobot yang mencerminkan proporsi kontribusinya terhadap prediksi akhir, dengan total seluruh bobot bernilai satu. Sami et al. (2024) menggunakan strategi ini untuk menggabungkan prediksi dari beberapa model rekomendasi, dengan prediksi akhir dirumuskan sebagai kombinasi linear dari skor prediksi masing-masing model yang dikalikan dengan bobot yang sesuai. Untuk sistem hibrid yang menggabungkan dua model, formula prediksi *weighted hybridization* dapat dituliskan sebagai:

$$\hat{r}_{ui} = \alpha \cdot \hat{r}_{ui}^A + \beta \cdot \hat{r}_{ui}^B \quad (16)$$

dengan *constraint*:

$$\alpha + \beta = 1, \alpha, \beta \in [0,1] \quad (17)$$

Keterangan:

- $\hat{r}_{ui}$  = prediksi *rating* pengguna u terhadap item i
- $\hat{r}_{ui}^A$  = prediksi *rating* model A untuk pengguna u terhadap item i
- $\hat{r}_{ui}^B$  = prediksi *rating* model B untuk pengguna u terhadap item i
- $\alpha$  = bobot model A
- $\beta$  = bobot model B

Nilai bobot  $\alpha$  dan  $\beta$  dapat ditentukan secara empiris melalui pencarian pada rentang 0 – 1 yang meminimalkan metrik kesalahan prediksi pada data validasi. Pendekatan ini memastikan proporsi kontribusi masing-masing model ditentukan berdasarkan performa aktual pada data, sehingga kombinasi yang dihasilkan bersifat adaptif terhadap karakteristik dataset yang digunakan.

#### 2.1.6 Mean Absolute Error, Mean Squared Error, Root Mean Squared Error

Evaluasi performa sistem rekomendasi berbasis prediksi rating dilakukan menggunakan metrik kesalahan yang mengukur selisih antara nilai rating aktual dengan nilai rating yang diprediksi oleh model. Tiga metrik yang digunakan dalam penelitian ini adalah *Mean Absolute Error* (MAE), *Mean Squared Error* (MSE), dan *Root Mean Squared Error* (RMSE) (Bobadilla et al., 2023).

*Mean Absolute Error* (MAE) mengukur rata-rata nilai absolut dari selisih antara *rating* aktual dan *rating* prediksi. MAE memberikan gambaran langsung seberapa jauh prediksi model menyimpang dari nilai sebenarnya dalam satuan yang sama dengan skala *rating*. MAE diformulasikan sebagai:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (18)$$

*Mean Squared Error* (MSE) mengukur rata-rata kuadrat selisih antara *rating* aktual dan *rating* prediksi. Pengkuadratan selisih menyebabkan MSE memberikan penalti yang lebih besar terhadap kesalahan prediksi yang jauh dari nilai aktual dibandingkan MAE. MSE diformulasikan sebagai:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (19)$$

*Root Mean Squared Error* (RMSE) merupakan akar kuadrat dari MSE. RMSE mengembalikan nilai kesalahan ke satuan yang sama dengan skala *rating* asli sehingga lebih mudah diinterpretasikan, sekaligus mempertahankan sifat MSE yang memberikan penalti lebih besar pada kesalahan besar. RMSE diformulasikan sebagai:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (20)$$

Keterangan:

- $n$  = jumlah pasangan rating aktual dan prediksi yang dievaluasi
- $y_i$  = nilai *rating* aktual k-i
- $\hat{y}_i$  = nilai *rating* prediksi k-i

Ketiga metrik ini bernilai non-negatif dan semakin kecil nilainya semakin baik performa model. RMSE lebih sensitif terhadap kesalahan besar karena sifat pengkuadratan yang diwarisi dari MSE, sedangkan MAE memberikan gambaran kesalahan rata-rata yang lebih merata tanpa memberikan penalti berlebih pada outlier (Bobadilla et al., 2023).

### 2.1.7 K-Fold Cross Validation

*K-fold cross validation* merupakan teknik evaluasi model yang membagi seluruh data menjadi k bagian yang berukuran sama, kemudian melatih dan menguji model sebanyak k kali secara bergantian (Abedin et al., 2026). Teknik ini mengatasi keterbatasan metode *holdout* biasa yang hanya melakukan satu kali pembagian data latih dan data uji, sehingga hasil evaluasinya bergantung pada bagaimana data kebetulan terbagi. Dengan menggunakan seluruh data untuk pelatihan dan pengujian secara bergantian, *k-fold cross validation* menghasilkan estimasi performa model yang lebih stabil dan dapat direplikasi.

Prosedur *k-fold cross validation* diawali dengan mengacak seluruh data, kemudian membaginya menjadi k *fold* yang berukuran sama. Pada setiap iterasi ke- $i$ , *fold* ke- $i$  digunakan sebagai data uji sementara  $k - 1$  *fold* sisanya digunakan sebagai data latih. Model dilatih dari awal pada setiap iterasi menggunakan data latih yang berbeda, kemudian dievaluasi pada data uji *fold* ke- $i$ . Proses ini diulang sebanyak k kali hingga setiap *fold* telah digunakan tepat satu kali sebagai data uji.



Metrik evaluasi akhir dihitung sebagai rata-rata dari metrik yang diperoleh di setiap fold, yaitu:

$$\bar{M} = \frac{1}{k} \sum_{i=1}^k M_i \quad (21)$$

Keterangan:

- $\bar{M}$  = nilai rata-rata metrik evaluasi dari  $k$  fold
- $M_i$  = nilai metrik evaluasi pada fold ke- $i$
- $K$  = jumlah fold

Pemilihan nilai  $k$  berpengaruh pada keseimbangan antara *bias* dan *variance* dari estimasi performa. Nilai  $k$  yang terlalu kecil menghasilkan data latih yang lebih sedikit sehingga estimasi cenderung *bias*, sedangkan nilai  $k$  yang terlalu besar dapat meningkatkan *variance* antar fold (Abedin et al., 2026). Nilai  $k = 10$  merupakan salah satu pilihan yang umum digunakan dalam penelitian *machine learning* (Abedin et al., 2026), meskipun pemilihan nilai  $k$  yang optimal bergantung pada karakteristik data dan model yang digunakan.

#### 2.1.8 Uji-t Berpasangan (*Paired t-test*)

Uji-t berpasangan (*paired t-test*) merupakan salah satu metode pengujian hipotesis yang digunakan ketika data yang dibandingkan berasal dari subjek yang sama namun diukur dalam dua kondisi yang berbeda (Rahmani et al., 2025). Metode ini membandingkan rata-rata dua kelompok data yang berpasangan untuk menentukan apakah perbedaan yang teramati signifikan secara statistik atau hanya merupakan variasi acak. Dua pengukuran dikatakan berpasangan apabila setiap nilai pada kelompok pertama memiliki pasangan yang bersesuaian pada kelompok kedua dari subjek yang sama.

Uji-t berpasangan dirumuskan dengan hipotesis nol ( $H_0$ ) dan hipotesis alternatif ( $H_1$ ) sebagai berikut (Rahmani et al., 2025):

- $H_0: \mu_1 - \mu_2 = 0$  (tidak terdapat perbedaan signifikan antara rata-rata kedua kelompok)
- $H_1: \mu_1 - \mu_2 \neq 0$  (terdapat perbedaan signifikan antara rata-rata kedua kelompok)

Statistik uji  $t$  dihitung menggunakan selisih antar pasangan data dengan rumus (Rahmani et al., 2025):

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} \quad (22)$$

Dengan derajat kebebasan

$$df = n - 1 \quad (23)$$

Keterangan:

- $\bar{d}$  = rata-rata selisih antara dua kelompok pengukuran berpasangan
- $s_d$  = simpang baku dari selisih
- $n$  = jumlah pasangan pengukuran
- $df$  = derajat kebebasan

## 2.2 Tinjauan Empiris

### 2.2.1 Deep Variational Models for Collaborative Filtering-Based Recommender Systems (Bobadilla et al., 2023)

Pada penelitian ini, penulis mengembangkan sistem rekomendasi berbasis *collaborative filtering* menggunakan beberapa varian model *variational autoencoder* (VAE), termasuk VAE standar, *Bernoulli VAE*, dan *Gaussian VAE*. Tujuan penelitian ini adalah untuk mengevaluasi apakah penambahan tahap variasional pada model *autoencoder* yang sudah ada dapat meningkatkan akurasi prediksi rating dibandingkan model *deep matrix factorization* konvensional. Penulis berargumen bahwa VAE menghasilkan ruang laten yang lebih teratur dan kontinu dibandingkan *autoencoder* biasa, sehingga lebih mampu menangkap preferensi pengguna secara probabilistik. Eksperimen dilakukan menggunakan beberapa dataset *benchmark* sistem rekomendasi. Evaluasi dilakukan menggunakan metrik MAE dan RMSE dengan skema pengujian *train-test split*. Hasil penelitian menunjukkan bahwa model-model berbasis VAE secara konsisten mengungguli model *deep matrix factorization* pada seluruh dataset yang diuji. Penelitian ini menjadi landasan empiris penggunaan VAE dalam konteks *collaborative filtering* pada penelitian yang dilakukan. Namun, penelitian ini tidak mengeksplorasi penggabungan VAE dengan teknik dekomposisi matriks seperti RSVD, dan tidak menerapkan *cross-validation* dalam proses evaluasinya.

### 2.2.2 A Deep Autoencoder-Based Hybrid Recommender System (Bougteb et al., 2022)

Pada penelitian ini, penulis membangun sebuah sistem rekomendasi hibrid yang menggabungkan *deep autoencoder* dengan SVD++ untuk mengatasi masalah *data sparsity* dan skalabilitas pada matriks rating pengguna-item. *Deep autoencoder* dengan 5 *hidden layer* digunakan untuk mempelajari representasi laten berdimensi rendah dari matriks rating yang *sparse* dan merekonstruksi *rating* yang hilang, sementara SVD++ dijalankan secara paralel untuk mempertahankan informasi korelasi antara faktor laten pengguna dan item, termasuk *implicit feedback*. Prediksi akhir dihasilkan melalui *weighted average* dari keluaran kedua komponen tersebut, dengan bobot optimal  $w = 0,9$  untuk SVD++ dan  $1 - w = 0,1$  untuk *deep autoencoder*. Eksperimen dilakukan menggunakan tiga dataset, yaitu MovieLens 100K, MovieLens 1M, dan Book-Crossing. Evaluasi dilakukan menggunakan metrik RMSE dan MAE dengan skema *train-test split* 75:25. Pada dataset MovieLens 100K, hasil yang diperoleh adalah RMSE sebesar 0,992 dan MAE sebesar 0,777, mengungguli dua model *baseline* hibrid yang diuji. Penelitian ini secara langsung memotivasi pendekatan yang digunakan dalam penelitian yang dilakukan, yaitu mengombinasikan model berbasis *autoencoder* dengan teknik dekomposisi matriks melalui *weighted average*. Meskipun demikian, terdapat perbedaan mendasar yaitu penelitian Bougteb et al. menggunakan *autoencoder* deterministik dan SVD++ yang memperhitungkan *implicit feedback*, sedangkan penelitian yang dilakukan menggunakan *variational autoencoder* dengan regularisasi KL *annealing* dan RSVD dengan *bias terms* yang dioptimasi menggunakan SGD pada data *explicit feedback*. Selain itu, penelitian ini tidak menerapkan *cross-validation* dalam proses evaluasinya.

### 2.2.3 Implementasi Regularized Singular Value Decomposition dalam Sistem Rekomendasi Buku Collaborative Filtering (Darma Putra & Santiyasa, 2025)

Pada penelitian ini, penulis membangun sistem rekomendasi buku menggunakan metode *collaborative filtering* dengan RSVD sebagai algoritma prediksi rating. RSVD digunakan untuk mendekomposisi matriks rating pengguna-

item ke dalam representasi faktor laten dengan meminimalkan *regularized squared error* melalui SGD. Penulis juga memanfaatkan nilai faktor laten item yang dihasilkan RSVD untuk menghitung *cosine similarity* antar buku sebagai dasar rekomendasi non-personal. Data yang digunakan adalah data primer yang dikumpulkan langsung dari siswa SMP Negeri 3 Kediri, terdiri dari 886 buku, 332 pengguna, dan 124.841 data rating dengan skala 1–5. Evaluasi dilakukan menggunakan metrik MAE dan RMSE dengan skema *holdout* 80:20. Hasil terbaik yang diperoleh adalah MAE sebesar 0,478 dan RMSE sebesar 0,686 dengan kombinasi 100 faktor laten dan nilai regularisasi 0,05. Penelitian ini juga menunjukkan bahwa penambahan regularisasi secara signifikan meningkatkan akurasi prediksi dibandingkan RSVD tanpa regularisasi. Penelitian ini memperkuat justifikasi penggunaan RSVD dalam penelitian yang dilakukan, khususnya dalam hal efektivitas regularisasi terhadap akurasi prediksi. Namun, penelitian ini berfokus pada domain rekomendasi buku dengan data primer berskala kecil, tidak mengeksplorasi penggabungan RSVD dengan model *deep learning* seperti VAE, dan tidak menerapkan *cross-validation* dalam evaluasinya.

#### **2.2.4 Hybrid Recommendation System for Movies Using Artificial Neural Network (Sharma & Shakya, 2024)**

Pada penelitian ini, penulis mengembangkan sistem rekomendasi film hibrid yang mengintegrasikan empat komponen: SVD yang telah ditingkatkan untuk prediksi rating berbasis *collaborative filtering*, *Content Driven* KNN berbasis *cosine similarity* untuk deteksi kemiripan film, IKSOM berbasis *EISEN cosine correlation distance* untuk pengklusteran, dan K-Means++ dengan metode *silhouette* untuk kategorisasi data film. Prediksi akhir dihasilkan melalui kombinasi skor dari keempat komponen tersebut. Data yang digunakan adalah MovieLens 25M yang berisi 25 juta rating dari 162.541 pengguna untuk 62.423 film. Evaluasi dilakukan menggunakan metrik RMSE dan MAE dengan skema *train-test split* 75:25. Hasil yang diperoleh menunjukkan RMSE sebesar 0,414 dan MAE sebesar 0,279, mengungguli berbagai metode *baseline*. Penelitian ini menunjukkan bahwa pendekatan hibrid yang menggabungkan SVD dengan metode lain dapat meningkatkan akurasi prediksi secara signifikan pada domain rekomendasi film.

### 2.2.5 A Deep Learning Based Hybrid Recommendation Model for Internet Users (Sami et al., 2024)


Pada penelitian ini, penulis mengembangkan model sistem rekomendasi hibrid yang mengintegrasikan *user-based* dan *item-based collaborative filtering*, *neural collaborative filtering* (NCF), *recurrent neural network* (RNN), dan *content-based filtering* berbasis TF-IDF. Prediksi akhir dihasilkan melalui kombinasi tertimbang dari keluaran seluruh komponen tersebut. Data yang digunakan adalah MovieLens 100K yang berisi 100.000 rating dari 943 pengguna untuk 1.682 film, yang merupakan dataset yang sama dengan penelitian yang dilakukan. Evaluasi dilakukan menggunakan metrik RMSE, MAE, Precision, dan Recall dengan skema *train-test split* 80:20. Hasil yang diperoleh setelah *hyperparameter tuning* adalah RMSE sebesar 0,7723 dan MAE sebesar 0,6018, mengungguli berbagai model *baseline* yang diuji pada dataset yang sama.

## BAB III

### ANALISIS DAN PERANCANGAN SISTEM

#### 3.1 Desain Sistem

Penelitian ini mengembangkan sistem rekomendasi film berbasis prediksi rating menggunakan pendekatan hybrid ensemble yang menggabungkan model Variational Autoencoder (VAE) dan Regularized Singular Value Decomposition (RSVD). Prediksi dari kedua model digabungkan melalui mekanisme weighted average ensemble untuk menghasilkan prediksi rating akhir. Secara keseluruhan, penelitian ini mencakup delapan tahap utama sebagaimana diilustrasikan pada **Gambar 3.1.**



Gambar 3.1. Metode Penelitian

Penelitian dimulai dengan pengumpulan dataset MovieLens 100K, dilanjutkan dengan *preprocessing* data yang mencakup normalisasi rating dan pembagian data menjadi partisi latih, validasi, dan uji. Selanjutnya dilakukan *hyperparameter tuning* untuk memperoleh konfigurasi optimal bagi kedua model, yang kemudian digunakan pada tahap pelatihan. Bobot *ensemble* dicari pada data validasi dan diterapkan saat evaluasi pada data uji. Untuk mengukur stabilitas dan generalisasi model secara lebih komprehensif, evaluasi dilanjutkan dengan *10-fold cross-validation* pada keseluruhan dataset, diikuti uji signifikansi statistik menggunakan *paired t-test*.

#### 3.2 Dataset

Data yang digunakan dalam penelitian ini adalah dataset MovieLens 100K yang diperoleh secara sekunder dari situs *grouplens.org*. Dataset ini merupakan salah satu dataset *benchmark* yang umum digunakan dalam penelitian sistem rekomendasi (Sami et al., 2024). MovieLens 100K terdiri dari 100.000 data rating yang diberikan oleh 943 pengguna terhadap 1.682 film, dengan skala rating 1


hingga 5. File yang digunakan dalam penelitian ini adalah *ratings.csv* yang memuat kolom *userId*, *movieId*, *rating*, dan *timestamp* sebagaimana ditunjukkan pada **Tabel 3.1**. Kolom *timestamp* tidak digunakan dalam penelitian ini karena model yang dikembangkan tidak mempertimbangkan dimensi waktu dalam prediksi rating.

Tabel 3.1. Contoh Data *ratings.csv*

| userId | movieId | rating | timestamp |
|--------|---------|--------|-----------|
| 1      | 1       | 4.0    | 964982703 |
| 1      | 3       | 4.0    | 964981247 |
| 1      | 6       | 4.0    | 964982224 |
| 1      | 47      | 5.0    | 964983815 |
| 1      | 50      | 5.0    | 964982931 |

### 3.3 Preprocessing Data

Preprocessing data dilakukan dalam tiga tahap utama, yaitu pembangunan matriks interaksi pengguna-film, normalisasi rating, dan pembagian data. Alur keseluruhan tahap *preprocessing* diilustrasikan pada **Gambar 3.2**.



Gambar 3.2. Metode Penelitian


Tahap pertama adalah pembangunan matriks interaksi pengguna-film. Data pada *ratings.csv* dipivot menjadi matriks berukuran  $943 \times 1.682$ , di mana baris merepresentasikan pengguna dan kolom merepresentasikan film. Setiap sel pada matriks berisi nilai rating yang diberikan pengguna terhadap film yang bersangkutan, sedangkan sel yang tidak memiliki rating diisi dengan nilai 0. Contoh matriks interaksi ditunjukkan pada **Tabel 3.2** dimana indeks baris adalah pengguna dan kolom adalah *film*.

Tabel 3.2. Contoh Matriks Interaksi

|     | 1   | 2   | 3   | 4   | 5   | 6   | ... |
|-----|-----|-----|-----|-----|-----|-----|-----|
| 1   | 4.0 | 0.0 | 4.0 | 0.0 | 0.0 | 4.0 | ... |
| 2   | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | ... |
| 3   | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | ... |
| 4   | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | ... |
| ... | ... | ... | ... | ... | ... | ... | ... |

Tahap kedua adalah normalisasi rating. Seluruh nilai rating pada matriks dinormalisasi ke rentang  $[0, 1]$  dengan membagi setiap nilai dengan nilai rating maksimum (5.0). Normalisasi ini diperlukan agar nilai masukan sesuai dengan fungsi aktivasi *sigmoid* pada lapisan *output decoder* VAE yang menghasilkan keluaran dalam rentang yang sama. Sel kosong yang bernilai 0 tetap bernilai 0 setelah normalisasi sehingga dapat dibedakan dari rating terendah yang bernilai 0.2.

Tahap ketiga adalah pembagian data menggunakan metode *hold-out* pada level rating individual. Seluruh 100.000 rating diacak dengan *random seed* 42 untuk memastikan reproduksibilitas, kemudian dibagi menjadi tiga partisi: 70% data latih (70.000 rating) untuk melatih VAE dan RSVD, 10% data validasi (10.000 rating) untuk menentukan bobot *ensemble* optimal, dan 20% data uji (20.000 rating) untuk evaluasi performa akhir model. Pembagian dilakukan pada level rating individual, bukan pada level pengguna, sehingga setiap pengguna dapat muncul di ketiga partisi sekaligus. Ilustrasi pembagian data ditunjukkan pada Gambar 3.3.



Gambar 3.3. Ilustrasi Pembagian Data



### 3.4 Perancangan Model

#### 3.4.1 Variational Autoencoder (VAE)

VAE yang dikembangkan dalam penelitian ini terdiri dari tiga komponen utama: *encoder*, *sampling*, dan *decoder*. *Encoder* menerima masukan berupa vektor rating pengguna dari matriks interaksi berukuran 1.682 dimensi. Sebelum melewati lapisan tersembunyi, masukan dikenai *dropout* untuk mencegah *overfitting*. Lapisan tersembunyi *encoder* terdiri dari dua lapisan *dense* dengan fungsi aktivasi ReLU, diikuti dua lapisan keluaran yang masing-masing menghasilkan vektor  $\mu$  ( $z\_mean$ ) dan  $\log \sigma^2$  ( $z\_log\_var$ ) yang merepresentasikan rata-rata dan log varians distribusi ruang laten.

Komponen *sampling* mengimplementasikan *reparameterization trick* agar proses pengambilan sampel dari ruang laten tetap dapat diturunkan secara matematis (*differentiable*) sehingga *backpropagation* dapat berjalan. Titik sampel laten  $z$  diperoleh melalui persamaan (7).

*Decoder* menerima vektor laten  $z$  dan merekonstruksinya kembali menjadi vektor prediksi rating berukuran 1.682 dimensi. Lapisan tersembunyi *decoder* merupakan kebalikan simetris dari *encoder*, yaitu dua lapisan *dense* dengan fungsi aktivasi ReLU. Lapisan keluaran *decoder* menggunakan fungsi aktivasi *sigmoid* yang menghasilkan nilai dalam rentang  $[0, 1]$ , sesuai dengan skala rating yang telah dinormalisasi.

Fungsi *loss* yang digunakan adalah fungsi *loss* Beta-VAE yang merupakan kombinasi dari *reconstruction loss* dan *KL divergence loss* menggunakan persamaan (6). *Reconstruction loss* dihitung menggunakan *masked MSE* yang hanya mempertimbangkan sel matriks yang memiliki nilai rating, sehingga model tidak belajar dari nilai 0 yang merepresentasikan rating yang tidak ada menggunakan persamaan (5). *KL divergence loss* meregulasi distribusi ruang laten agar mendekati distribusi normal standar menggunakan persamaan (4).

Hyperparameter  $\beta$  dikontrol secara dinamis melalui mekanisme *KL annealing* untuk mencegah *posterior collapse*, yaitu kondisi di mana *encoder* mengabaikan masukan dan menghasilkan distribusi laten yang identik untuk semua

pengguna (Wang et al., 2025). Pada awal pelatihan  $\beta$  ditetapkan sebesar 0 sehingga model fokus meminimalkan *reconstruction loss* terlebih dahulu. Nilai  $\beta$  kemudian dinaikkan secara linear hingga mencapai nilai target yang diperoleh dari hasil *hyperparameter tuning*. Model dioptimasi menggunakan algoritma Adam. Nilai *learning rate*, *batch size*, *dropout rate*, dimensi ruang laten, dan jumlah unit pada setiap lapisan tersembunyi ditentukan melalui proses *hyperparameter tuning*.

### 3.4.2 Regularized Singular Value Decomposition (RSVD)

RSVD yang dikembangkan dalam penelitian ini mengimplementasikan faktorisasi matriks dengan tiga komponen utama yaitu bias global ( $\mu$ ), bias pengguna ( $b_u$ ), dan bias item ( $b_i$ ), di samping matriks faktor laten  $U$ ,  $\Sigma$ , dan  $V$ . Prediksi rating pengguna  $u$  terhadap item  $i$  diformulasikan dengan persamaan (9). Parameter model diinisialisasi sebagai berikut:

- $\mu$  dihitung sebagai rata-rata global dari seluruh rating pada data latih
- $b_u$  dan  $b_i$  diinisialisasi dengan nilai 0
- matriks  $U$  dan  $V$  diinisialisasi dengan nilai acak dari distribusi normal dengan skala 0.1
- matriks  $\Sigma$  diinisialisasi sebagai matriks identitas.

Inisialisasi  $\Sigma$  sebagai matriks identitas dipilih untuk mencegah *vanishing gradient* pada epoch-epoch awal pelatihan, karena inisialisasi dengan nilai mendekati 0 menyebabkan gradien  $U$  dan  $V$  ikut terhambat secara kaskade.

Model dilatih menggunakan *Stochastic Gradient Descent* (SGD) dengan fungsi *loss* yang merupakan kombinasi *reconstruction loss* dan penalti regularisasi L2 menggunakan persamaan (10). Pembaruan parameter dilakukan hanya pada pasangan  $(u, i)$  yang memiliki rating aktual, sehingga sel kosong pada matriks interaksi tidak mempengaruhi proses pelatihan. Aturan pembaruan untuk setiap parameter adalah dilakukan melalui persamaan (12) – (15). Perlu diperhatikan bahwa regularisasi L2 diterapkan pada  $U$ ,  $V$ ,  $b_u$ , dan  $b_i$ , namun tidak diterapkan pada  $\Sigma$ . Keputusan desain ini diambil berdasarkan eksperimen awal yang menunjukkan bahwa regularisasi pada  $\Sigma$  menyebabkan nilai-nilainya mendekati 0 secara kaskade sehingga menghambat gradien  $U$  dan  $V$ .

Untuk mencegah *overfitting*, RSVD menggunakan mekanisme *early stopping* berbasis *validation MSE*. Sebelum pelatihan dimulai, sebanyak 10% dari

rating data latih disisihkan sebagai *validation set* internal menggunakan metode *hold-out*. Pada setiap akhir epoch, model mengevaluasi *validation MSE* dan menyimpan *snapshot* bobot terbaik. Pelatihan dihentikan apabila tidak terdapat perbaikan *validation MSE* selama sejumlah epoch yang ditentukan oleh parameter *patience*. Setelah pelatihan selesai, bobot dikembalikan ke *snapshot* terbaik. *Validation MSE* digunakan sebagai kriteria *early stopping* karena *training MSE* selalu menurun secara monoton sehingga tidak mencerminkan performa model pada data yang belum dilihat. Nilai *learning rate*, koefisien regularisasi  $\lambda$ , jumlah faktor laten, dan *patience* ditentukan melalui proses *hyperparameter tuning*.

### 3.4.3 Model Hybrid dengan Weighted Average Ensemble

Penelitian ini mengembangkan model *hybrid* yang menggabungkan prediksi VAE dan RSVD melalui mekanisme *weighted average ensemble*. Pendekatan *hybrid* dipilih karena VAE dan RSVD memodelkan preferensi pengguna dari sudut pandang yang berbeda, VAE mempelajari representasi laten melalui distribusi probabilitas, sedangkan RSVD mengdekomposisi matriks rating melalui faktorisasi laten deterministik dengan bias terms.

Sebelum digabungkan, prediksi dari kedua model dinormalisasi ke skala rating asli (1–5) dan dibatasi (*clipping*) agar tidak melampaui rentang tersebut. Prediksi *hybrid* diformulasikan dengan persamaan (16) dan (17). Nilai  $\alpha$  optimal ditentukan melalui *grid search* pada data validasi (10%) yang telah disisihkan pada tahap *preprocessing*. Pencarian dilakukan dengan mencoba seluruh nilai  $\alpha$  dari 0.00 hingga 1.00 dengan langkah 0.01, menghasilkan 101 kandidat nilai. Untuk setiap nilai  $\alpha$ , RMSE dihitung antara prediksi *hybrid* dan rating aktual pada data validasi. Nilai  $\alpha$  yang menghasilkan RMSE terendah di data validasi dipilih sebagai bobot final dan digunakan untuk menghitung prediksi *hybrid* pada data uji. Dengan pendekatan ini, pemilihan  $\alpha$  sepenuhnya didasarkan pada data validasi sehingga evaluasi pada data uji tetap tidak bias.

## 3.5 Hyperparameter Tuning

*Hyperparameter tuning* dilakukan secara terpisah untuk VAE dan RSVD menggunakan data latih (70%). Tujuan dari tahap ini adalah menemukan

konfigurasi hyperparameter yang menghasilkan performa terbaik sebelum model dilatih secara final dan dievaluasi.

### 3.5.1 Hyperparameter Tuning VAE

*Tuning* VAE dilakukan menggunakan *framework* Optuna dengan algoritma *Tree-structured Parzen Estimator* (TPE). TPE membangun model probabilistik dari hasil *trial* sebelumnya untuk menentukan kombinasi hyperparameter berikutnya yang paling menjanjikan agar pencarian menjadi lebih efisien. Setiap *trial* melatih VAE selama 30 *epoch* dan menggunakan *reconstruction loss* pada epoch terakhir sebagai kriteria seleksi. *Reconstruction loss* dipilih sebagai kriteria bukan *total loss* agar hasil tidak bias terhadap nilai  $\beta$  yang kecil, karena *total loss* yang rendah dapat dicapai sekadar dengan meminimalkan kontribusi KL divergence melalui  $\beta$  kecil tanpa benar-benar meningkatkan kualitas rekonstruksi. Total *trial* yang dijalankan adalah 200. Ruang pencarian hyperparameter VAE ditunjukkan pada Tabel 3.3.

Tabel 3.3. Ruang Pencarian Hyperparameter VAE

| <i>Hyperparameter</i>                                | Nama Variabel | Ruang Pencarian                                            |
|------------------------------------------------------|---------------|------------------------------------------------------------|
| Dimensi ruang laten                                  | latent_dim    | 20, 50, 100, 200                                           |
| Kecepatan belajar                                    | learning_rate | 0.0001, 0.0005, 0.001, 0.005, 0.01                         |
| Jumlah sampel per iterasi                            | batch_size    | 64, 128, 256                                               |
| Laju <i>dropout</i> pada lapisan tersembunyi         | dropout_rate  | 0.1, 0.2, 0.3, 0.4                                         |
| Jumlah unit pada setiap lapisan tersembunyi          | hidden_dims   | [512, 256], [512, 256, 128], [1024, 512], [1024, 512, 256] |
| Bobot KL divergence pada fungsi <i>loss</i> Beta-VAE | beta          | 0.01, 0.05, 0.1, 0.3, 0.5, 0.8, 1.0                        |

Pemilihan rentang kandidat untuk setiap hyperparameter VAE didasarkan pada karakteristik dataset dan arsitektur model.

- `latent_dim` divariasikan dari 20 hingga 200 untuk mengeksplorasi trade-off antara kapasitas representasi ruang laten dan risiko *overfitting*. Dimensi terlalu kecil tidak mampu menangkap kompleksitas preferensi pengguna, sedangkan dimensi terlalu besar berpotensi mempelajari *noise*.
- `learning_rate` mencakup rentang lebar dari 0.0001 hingga 0.01 karena sensitivitas konvergensi VAE terhadap nilai ini cukup tinggi, terutama akibat interaksi antara *reconstruction loss* dan KL divergence.
- `batch_size` dibatasi pada nilai 64, 128, dan 256 mengingat ukuran dataset (943 pengguna). *Batch size* yang terlalu besar akan menghasilkan terlalu sedikit iterasi per epoch.
- `dropout_rate` diuji pada rentang 0.1 - 0.4 karena nilai di bawah 0.1 memberikan regularisasi yang tidak signifikan, sedangkan nilai di atas 0.4 berisiko menghilangkan terlalu banyak informasi dari vektor rating yang sudah sangat *sparse*.
- `hidden_dims` mencakup empat variasi arsitektur dua dan tiga lapisan dengan jumlah unit yang berbeda untuk mengeksplorasi kedalaman dan lebar jaringan secara bersamaan.
- `beta` mencakup rentang 0.01 hingga 1.0 karena nilai  $\beta$  yang terlalu besar cenderung menyebabkan *posterior collapse*, sedangkan nilai yang terlalu kecil membuat regularisasi ruang laten tidak efektif.

### 3.5.2 Hyperparameter Tuning RSVD

*Tuning* RSVD dilakukan menggunakan *exhaustive grid search* yang mencoba seluruh kombinasi dari ruang pencarian secara sistematis. Total kombinasi yang dievaluasi adalah  $3 \times 4 \times 4 = 48$  kombinasi. Setiap kombinasi melatih RSVD selama 15 *epoch* dan menggunakan *total loss* (MSE + penalti L2) pada epoch terakhir sebagai kriteria seleksi. Ruang pencarian hyperparameter RSVD ditunjukkan pada Tabel 3.4.

Tabel 3.4. Ruang Pencarian *Hyperparameter* RSVD

| <i>Hyperparameter</i>             | Nama Variabel              | Ruang Pencarian          |
|-----------------------------------|----------------------------|--------------------------|
| Jumlah dimensi faktor laten       | <code>n_factors</code>     | 10, 20, 50               |
| Kecepatan belajar SGD             | <code>learning_rate</code> | 0.001, 0.005, 0.01, 0.02 |
| Koefisien penalti regularisasi L2 | <code>lambda_reg</code>    | 0.001, 0.005, 0.01, 0.02 |

Pemilihan rentang kandidat untuk setiap hyperparameter RSVD mempertimbangkan karakteristik dataset dan kompleksitas komputasi.

- `n_factors` diuji pada nilai 10, 20, dan 50 karena RSVD dengan jumlah faktor laten yang besar membutuhkan waktu komputasi yang jauh lebih lama akibat iterasi SGD per pasangan ( $u, i$ ).
- `learning_rate` diuji pada rentang 0.001 hingga 0.02 karena SGD pada RSVD lebih sensitif terhadap nilai ini dibandingkan optimizer Adam pada VAE. Nilai terlalu besar menyebabkan divergensi, sedangkan nilai terlalu kecil memperlambat konvergensi secara signifikan.
- `lambda_reg` diuji pada rentang 0.001 hingga 0.02 untuk menyeimbangkan antara regularisasi yang cukup untuk mencegah *overfitting* dan tidak terlalu agresif sehingga menghambat kemampuan model mempelajari pola rating.

### 3.6 Evaluasi Model

Setelah hyperparameter optimal diperoleh melalui proses *hyperparameter tuning*, VAE dan RSVD dilatih secara final menggunakan data latih (70%). Bobot *ensemble  $\alpha$*  kemudian ditentukan pada data validasi (10%) melalui prosedur *grid search*. Model yang telah dilatih selanjutnya dievaluasi melalui dua tahap. Tahap pertama adalah evaluasi *hold-out* pada data uji (20%) yang tidak pernah digunakan pada proses pelatihan maupun penentuan bobot *ensemble*. Tahap kedua adalah *10-fold cross-validation* pada keseluruhan dataset untuk mengukur stabilitas dan kemampuan generalisasi model secara lebih komprehensif. Signifikansi statistik perbedaan performa antar model kemudian diuji menggunakan *paired t-test*.


#### 3.6.1 Metrik Evaluasi

Evaluasi performa model diukur menggunakan dua metrik, yaitu *Mean Absolute Error* (MAE) dan *Root Mean Squared Error* (RMSE) sebagaimana diformulasikan pada persamaan (18) dan (20). Kedua metrik ini mengukur selisih antara nilai rating aktual dengan nilai rating yang diprediksi oleh model. MAE memberikan gambaran rata-rata kesalahan prediksi secara merata, sedangkan RMSE memberikan penalti yang lebih besar terhadap kesalahan prediksi yang jauh dari nilai aktual karena sifat pengkuadratnya. Nilai kedua metrik bersifat non-negatif dan semakin kecil nilainya semakin baik performa model.

#### 3.6.2 10-Fold Cross-Validation

10-fold cross-validation dilakukan pada keseluruhan dataset untuk mengukur stabilitas dan kemampuan generalisasi model secara lebih komprehensif dibandingkan evaluasi hold-out tunggal. Nilai  $k = 10$  dipilih berdasarkan

pertimbangan keseimbangan antara bias dan variance dari estimasi performa sebagaimana dijelaskan pada tinjauan teori.



Gambar 3.4. Struktur *Cross Validation*

Pembagian fold dilakukan pada level rating individual, bukan pada level pengguna. Seluruh rating dikelompokkan ke dalam 10 fold secara acak, sehingga setiap fold berisi sekitar 10% dari total rating. Struktur partisi data pada setiap fold diilustrasikan pada **Gambar 3.4**. Pada setiap iterasi fold ke- $i$ , sekitar 10.000 *rating* pada fold ke- $i$  digunakan sebagai data uji (*test fold*), sedangkan 90.000 *rating* sisanya dibagi lebih lanjut menjadi data latih-dalam (*train\_inner*,  $\pm 81.000$  *rating*) dan data validasi-dalam (*val\_inner*,  $\pm 9.000$  *rating*) menggunakan skema *hold-out* 90/10.

Dari masing-masing partisi ini, dibangun dua matriks interaksi pengguna-item yang terpisah, matriks *train\_inner* yang hanya berisi rating pada posisi *train\_inner*, dan matriks uji yang hanya berisi rating pada posisi *test fold*. Posisi

yang tidak termasuk dalam partisi masing-masing matriks dibiarkan bernilai nol dan dikecualikan dari perhitungan metrik melalui masked loss pada VAE dan seleksi indeks eksplisit pada RSVD.

Pada setiap iterasi, VAE dan RSVD dilatih secara paralel dari awal menggunakan `train_inner` dengan hyperparameter optimal yang diperoleh dari Sub-bab 3.5. Prediksi dari kedua model kemudian dihasilkan pada posisi `rating_val_inner` untuk keperluan pencarian bobot ensemble. Pencarian bobot  $\alpha$  dilakukan melalui grid search pada `val_inner` menggunakan prosedur yang sama dengan Sub-bab 3.4.3. Bobot  $\alpha$  terbaik yang diperoleh dari `val_inner` selanjutnya digunakan untuk menghitung prediksi hybrid pada test fold, di mana RMSE dan MAE dihitung untuk ketiga model (VAE, RSVD, dan hybrid) menggunakan rating aktual *test fold*. Hasil setiap *fold* disimpan dan proses ini diulang sebanyak 10 kali hingga seluruh fold telah digunakan sebagai data uji tepat satu kali. Metrik akhir dilaporkan sebagai rata-rata  $\pm$  standar deviasi dari 10 *fold* menggunakan [persamaan \(21\)](#).

### 3.6.3 Uji Signifikansi Statistik (*Paired t-Test*)

Uji signifikansi statistik dilakukan untuk membuktikan bahwa perbedaan performa adalah perbedaan yang bermakna secara statistik. Pengujian *paired t-test* menggunakan [persamaan \(22\) dan \(23\)](#), dengan data berpasangan berupa metrik per *fold* dari *10-fold cross-validation*. Setiap pasangan nilai metrik dari dua model yang dibandingkan diperlakukan sebagai pengamatan berpasangan karena keduanya dievaluasi pada partisi data uji yang identik di setiap *fold*.

Pengujian dilakukan pada metrik RMSE dan MAE, mencakup tiga pasangan perbandingan yaitu *Hybrid* vs. RSVD, *Hybrid* vs. VAE, dan RSVD vs. VAE. Hipotesis yang diuji adalah sebagai berikut:

- $H_0$ : Tidak terdapat perbedaan yang signifikan antara rata-rata metrik kedua model yang dibandingkan
- $H_1$ : Terdapat perbedaan yang signifikan antara rata-rata metrik kedua model yang dibandingkan

Tingkat signifikansi yang digunakan adalah  $\alpha = 0,05$ .  $H_0$  ditolak apabila *p-value*  $< 0,05$ , yang berarti perbedaan performa antar model signifikan secara statistik pada tingkat kepercayaan 95%.



**BAB IV**  
**HASIL DAN PEMBAHASAN**